

Trading Algorithmique et Arbitrage Statistique (LF et HF)

Partie 3 - Modèles et stratégies d'arbitrage statistique

Diquel Dos Santos
Head of Fixed Income Quantitative Research at Candriam

Université Lille I - Master 2 Mathématiques et Finance

Mars 2023

Introduction (1)

- Famille de stratégies cherchant **des relations statistiquement persistentes**
=> exploitation des deconnexions

$$y_t = f_t(x_t) + \varepsilon_t$$

- **Objectif** : isoler un processus stationnaire ε_t et jouer le retour à la moyenne (Z-Scoring)
- **Tests de stationnarité** : idéalement sur les résidus out-sample mais en pratique plutôt l'un des 2 choix suivants
 - estimation glissante + tests réalisés sur les résidus out-sample
 $\varepsilon_t = y_t - \hat{f}_{t|t-1}(x_t)$
 - test in-sample en supposant la conservation de la stationnarité => on fige les paramètres lors de la phase de génération de signaux
- **Problématique clef** : trouver l'équilibre entre lien financier et lien statistique (potentiellement fortuit)

Introduction (2)

- **Choix des variables :**

- analyse qualitative (financière et/ou économique)
- corrélations historiques et régressions linéaires
- méthodes de classification non-supervisée (**clustering**) => utilisation d'une distance entre une variable et un groupe de variables (ex : distance de Mahalanobis $d_M(X, Y) = \|X - Y\|_M = (X - Y)^T \Sigma^{-1} (X - Y)$)

- Le choix des variables est aussi conditionné par le type de signaux souhaités :

- **signaux directionnels** : il suffit que $y_t = y_t^{theo} + \varepsilon_t$ soit tradable
- **signaux de valeur relative** : y_t et toutes les variables x_t du modèle doivent être tradables => réplication possible au moins à l'ordre 1 de $f_t(x_t) \approx \Delta_t^f x_t$

Sommaire


- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires
- 3 Modèles linéaires
- 4 Cointégration
- 5 Modèles dynamiques
- 6 Arbitrage statistique de volatilité
- 7 Arbitrage statistique de taux

Arbitrage Statique vs Arbitrage Statistique

- **Arbitrage statique** : relation devant être vérifiée à tout instant sous peine d'arbitrage (stratégie générant sans risque un gain positif)
- **Arbitrage statistique** : relation statistiquement vérifiée sur une période suffisamment longue pour éaliser l'arbitrage
- **Frontière floue entre les 2 types d'arbitrage** :
 - une relation d'arbitrage statique n'est presque jamais vérifiée (coûts et bruits de microstructure)
 - on peut modéliser l'erreur observée par un processus stationnaire
$$\varepsilon_t = y_t - f_t(x_t)$$
 - le Z-Scoring normalise l'erreur par sa moyenne et son écart-type => prend ainsi compte implicitement les coûts et bruits empêchant l'arbitrage statique
- **Illustration de l'approche** : 3 exemples types basés sur des principes financiers dans le cadre des marchés de Credit
 - Credit Skew (Arbitrage d'indice)
 - Arbitrage Credit-Equity (Arbitrage Cross-Asset)
 - CDS-Bond Basis (Arbitrage Cross-Market)

Arbitrage d'Indice : Credit Skew

- **CDS** : innovation financière majeure des années 90 (JPMorgan)
 - contrat d'assurance contre le défaut d'une référence de Credit
 - structuré comme un swap => 2 jambes (premium leg + default leg)
 - initiés à valeur nulle
 - différentes maturités traitées entre 1y et 10y => structure par terme de Credit
- **Facteurs ayant favorisé l'envol du marché :**
 - titrisation des CDS au sein de CSO
 - 1999-2000 : crise des dettes émergentes + l'éclatement de la bulle internet
 - 2003 : création d'indices de Credit standardisés (Itraxx et CDX)



Credit Skew : CDS Single Name

- **Notions importantes dans la valorisation des CDS :**

- R : recouvrement en cas de défaut de la référence de Credit
- λ_t : taux de défaut (ou intensité de défaut) instantané
- $P(t, T) = E_t^Q \left[e^{-\int_t^T \lambda_s ds} \right]$: probabilité risque-neutre de « survie » jusqu'à T sachant la survie en t
- $P_D(t, T) = 1 - P(t, T)$: probabilité de défaut risque-neutre avant T sachant la survie en t
- $\bar{B}(t, T) = E_t^Q \left[e^{-\int_t^T (r_s + \lambda_s) ds} \right] = B(t, T) P(t, T)$: prix zéro-coupon risqué à recouvrement nul
- $\overline{AP}(t, T) = \sum_{i=1}^n \bar{B}(t, T_i)$: prix de l'annuité risquée sur un échéancier de dates $(T_i)_{i \in [1, n]}$

- **Valorisation d'un CDS** payeur de prime fixe spd_0 :

$$PV_{CDS}(t, T) = \overline{AP}(t, T) (spd_t - spd_0)$$

Credit Skew : Indices de Credit

- **Principales caractéristiques :**

- structurés comme un CDS Single Name
- la jambe de défaut compense tout défaut éventuel au sein d'un panier équi pondéré de références de Credit
- en cas de défaut $\Rightarrow$ le notionnel est diminué de la quantité correspondant à l'entité défaillante
- Itraxx et CDX composés des 125 CDS IG les plus liquides (EUR et USD)
- réactualisation de l'indice tous les 6 mois (juin et décembre) par émission de nouveaux contrats de maturités standards

- **Indice Credit équivalent à n CDS Single Name** $\Rightarrow$ on peut montrer que la relation statique suivante doit toujours être vérifiée


$$spd_I(t, T) = \frac{\sum_{i=1}^n \overline{AP_i}(t, T) spd_i(t, T)}{\sum_{i=1}^n \overline{AP_i}(t, T)}$$

Credit Skew

- **Relation jamais vérifiée empiriquement** (coûts et bruits de microstructure)
=> **Skew de Credit**

$$\text{CreditSkew}(t, T) = \text{spd}_I(t, T) - \frac{\sum_{i=1}^n \overline{AP}_i(t, T) \text{spd}_i(t, T)}{\sum_{i=1}^n \overline{AP}_i(t, T)}$$

On-the-run Itraxx Credit Skew



Arbitrage d'indice : Credit Skew

- Mis à part durant la période 2008-2009 (pic de la crise financière) **le Skew de Credit est globalement stationnaire**
- **Modèle d'arbitrage statistique :**

$$CreditSkew(t, T) = \varepsilon_t$$

- Le marché des CDS est encore largement OTC => des Hedge Funds se sont montés avec succès pour réaliser spécifiquement cet arbitrage (statique ou statistique)

Arbitrage Cross-Asset : Credit-Equity

- **Marché Equity** : trading de toute l'information influençant la valeur nette d'une entreprise
- Ce marché incorpore donc toute information liée au défaut :

$$P_D(t, T) = Q(S_T = 0)$$

- L'information la plus complète sur la distribution anticipée de S_t est contenue dans le smile de volatilité implicite
- **Calcul d'un spread théorique $spd_{theo}(t, T)$:**
 - ① modèle CEV (0 est un point atteignable par S_t)

$$\frac{dS_t}{S_t} = (r_t - m_t - d_t) dt + \sigma \left(\frac{S_t}{S_0} \right)^\gamma dW_t^Q$$

- ② paramètres $\sigma > 0$ et $\gamma < 0$ calibrés sur le smile de volatilité
 - ③ on infère la courbe de défaut $P_D(t, T) = Q(S_T = 0)$
 - ④ calcul de $spd_{theo}(t, T)$
- **Modèle d'arbitrage statistique** : implicitement cette approche suppose le marché Equity « leading » (faux en marché « distressed »)

$$spd_{market}(t, T) - spd_{theo}(t, T) = \varepsilon_t$$

Arbitrage Cross-Market : CDS-Bond Basis (1)

- **Arbitrage Cross-Market** : comparer la valeur d'une variable tradée sur deux marchés différents
- La probabilité de défaut est tradée principalement sur 2 marchés :
 - marché des Bonds
 - marché des CDS
- L'information la plus complète sur la distribution anticipée de S_t est contenue dans le smile de volatilité implicite
- **Comparaison des 2 marchés** $\Rightarrow$ introduction de la notion **Credit Basis** :

$$CreditBasis(t, T) = spd_{bond}(t, T) - spd_{CDS}(t, T)$$

- **Définition très imparfaite** :
 - ne prend pas en compte la structure par terme de défaut
 - le bond et le CDS ont des structures de flux différentes
 - le spread d'un CDS n'est vraiment comparable qu'au spread d'un Bond au pair

Arbitrage Cross-Market : CDS-Bond Basis (2)

- **Definition alternative corrigeant ces défauts :**

- ① Calibration une structure par terme d'intensité de défaut sur le marché des CDS
- ② Pour un straight bond portant sur la même référence de Crédit et de maturité T , on calcule la base à rajouter à la courbe de défaut des CDS pour aboutir au prix de marché
- ③ Transformation (éventuelle) de cette base en un spread de CDS de maturité T
 $\Rightarrow CreditBasis(t, T)$

- **Base généralement positive** (sauf en période « distressed ») car le marché des CDS est souvent plus liquide que celui des bonds

- **Modèle d'arbitrage statistique :**

$$CreditBasis(t, T) = \varepsilon_t$$

- **Z-Scoring** $\Rightarrow$ génération de signaux de retour à la moyenne

- $ZScore > 2\sigma \Rightarrow$ signal « Short Base » $\Rightarrow$ Short Bond - Long CDS
- $ZScore < -2\sigma \Rightarrow$ signal « Long Base » $\Rightarrow$ Long Bond - Short CDS

Arbitrage Cross-Market : CDS-Bond Basis (3)

- **Problèmes importants en suspens :**
 - quels CDS pour réaliser concrètement cette stratégie ?
 - quels ratio de couverture (HR) choisir ?
- On utilise **en pratique un seul CDS** de maturité la plus proche de celle du Bond **avec un des ratio HR suivants :**
 - $HR = 1$: simple couverture en nominal.
 - $HR = \frac{P-R}{100-R}$: couverture en cas de défaut immédiat
 - $HR = \frac{P}{100}$: couverture en valeur de marché à recouvrement nul
 - $HR = \frac{\Delta_{bond}}{\Delta_{CDS}}$: couverture au premier ordre contre les mouvements parallèles
- Problème complexe car **la stratégie est soumise à 2 risques principaux :**
 - risque marked-to-market
 - risque de défaut
- **Si l'on peut porter la position jusqu'à maturité**
 - possibilité de réaliser l'arbitrage par réplication récursive des flux risqués du Bond à l'aide de CDS forwards
 - on projette ensuite cette solution optimale sur un seul pilier pour limiter les coûts
 - solution plus efficiente qu'avec les ratios HR usuels

Sommaire

- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires**
- 3 Modèles linéaires
- 4 Cointégration
- 5 Modèles dynamiques
- 6 Arbitrage statistique de volatilité
- 7 Arbitrage statistique de taux

Modèles non-linéaires


- **Démarche** : modéliser la valeur théorique de y_t par un modèle explicatif non-linéaire

$$y_t = f_t(x_t) + \varepsilon_t$$

- $f_t(x_t)$ n'est généralement pas tradable => **signaux directionnels non-couverts**
- Les modèles de classification peuvent pratiquement toujours être transformés en modèles de régression
- **Principaux modèles** :
 - réseaux de neurones
 - régression SVM
- **Principal défaut des modèles non-linéaires** : l'aspect statistique est privilégié par rapport à l'aspect financier

Réseaux de neurones

- **Mêmes principes que dans le cadre de classification**
- **Seuls les inputs et outputs du réseau changent :**
 - **Input** : $X = (x_1, \dots, x_D)$ correspond aux D variables explicatives du modèle
 - **Output** : $Y = (y_1, \dots, y_K)$ est le vecteur des variables modélisées souvent réduit au cas $K = 1$
- **Principaux défauts :**
 - problèmes de convergence (nombreux minimums locaux)
 - **manque de stabilité et robustesse** => rédhibitoire pour l'arbitrage statistique



Régression SVM (1)

- Application moins directe des principes SVM
- **Transformation spatiale** pour se ramener à un cadre linéaire :

$$Y = f(X) = w^T \phi(X) + b$$

- **Régression non-linéaire classique** => minimisation de l'erreur quadratique régularisée suivante :

$$\frac{1}{2} \sum_{i=1}^n (Y_i - f(X_i))^2 + \frac{\lambda}{2} \|w\|^2$$

- **La régression SVM utilise plutôt la fonction d'erreur dite « ϵ -insensitive » :**


$$E_{\epsilon}[z] = \begin{cases} 0 & \text{si } |z| \leq \epsilon \\ |z| - \epsilon & \text{sinon} \end{cases}$$

- **Critère d'estimation SVM :**

$$C \sum_{i=1}^n E_{\epsilon}(Y_i - f(X_i)) + \frac{1}{2} \|w\|^2$$


Régression SVM (2)

L'estimation des paramètres devient alors insensible aux éléments situés dans le tube borné par ϵ



Régression SVM (3)

- Introduction des **variables auxiliaires** $\xi_i \geq 0$ et $\hat{\xi}_i \geq 0$ associées à chaque élément (X_i, Y_i) de l'ensemble d'apprentissage
- Elles représentent un **élargissement possible du tube d'insensibilité** de part et d'autre de la fonction estimée
- Pour les points situés à l'intérieur du tube d'insensibilité, on aura $\xi_i = \hat{\xi}_i = 0$



Régression SVM (4)

- **Problème quadratique sous contraintes** à résoudre :

$$\begin{aligned} \underset{w, b}{\operatorname{argmax}} \quad & C \sum_{i=1}^n \left(\xi_i + \hat{\xi}_i \right) + \frac{1}{2} \|w\|^2 \\ \text{s.c.} \quad & Y_i \leq f(X_i) + \varepsilon + \xi_i \\ & Y_i \geq f(X_i) - \varepsilon - \hat{\xi}_i \end{aligned}$$

- Le problème dual introduit les **multiplicateurs de Lagrange** a_i et $\hat{a}_i$ associés respectivement à ξ_i et $\hat{\xi}_i$
- **La solution finale ne dépend que des vecteurs supports** $X_{i \in S}$ définis par $a_i \neq 0$ et $\hat{a}_i \neq 0$ et nécessairement situés en dehors du tube d'insensibilité :

$$f(X) = \sum_{i \in S} (a_i - \hat{a}_i) k(X, X_i) + b$$

- **Principaux avantages :**

- estimation aisée (problème quadratique)
- solution ne dépendant que d'un nombre limité de vecteurs supports
- **solution stable et robuste**

Sommaire

- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires
- 3 Modèles linéaires**
- 4 Cointégration
- 5 Modèles dynamiques
- 6 Arbitrage statistique de volatilité
- 7 Arbitrage statistique de taux

Modèles linéaires

- **Avantages de l'approche Relative Value :**
 - position directionnelle couverte $\Rightarrow$ moins risqué
 - réplication du processus stationnaire $\varepsilon_t = y_t - f_t(x_t)$
- **Importance accordée aux modèles linéaires en arbitrage statistique :**
 - $f(x_t) = \beta x_t + \alpha$ peut alors être répliqué (sans biais) à l'aide d'instruments directement liés à x_t
 - rend possible les stratégies de Relative Value
- Modèles souvent basés sur les prix mais aussi sur les rendements
- **Qualité d'un modèle d'arbitrage statistique $\Rightarrow$ 4 critères principaux :**
 - **stationnarité** : objectif principal de l'arbitrage statistique
 - **stabilité** : afin d'éviter des rebalancements trop fréquents (coûteux)
 - **robustesse** : l'estimation des paramètres ne doit pas être trop sensible à la violation de certaines hypothèses du modèle et aux outliers
 - **discrimination** : les paramètres β estimés doivent être significativement différents de zéro

Régression linéaire (1)

- **Modèle de régression linéaire classique :**

$$y_t = \beta^T X_t + \alpha + \varepsilon_t$$

- **Principales hypothèses sur les résidus ε_t :**

- sans biais : $E[\varepsilon_t] = 0$
- homoscédastique : $E[\varepsilon_t^2] = \sigma_\varepsilon^2$
- sans autocorrélation : $E[\varepsilon_t \varepsilon_{t'}] = 0$
- indépendant des variables explicatives : $\text{Cov}[x_t, \varepsilon_t] = 0$

- Matrice d'autocovariance de l'erreur :

$$\Omega_\varepsilon = \sigma_\varepsilon^2 I$$

- **Estimateur MCO de $\hat{\beta}_t$ sur la fenêtre $[t - n + 1, t]$:**

$$\begin{aligned}\hat{\beta}_t &= \underset{\beta_t, \alpha_t}{\operatorname{argmin}} \left\| Y - (\beta_t^T X + \alpha_t) \right\|_2^2 \\ &= \underset{\beta_t, \alpha_t}{\operatorname{argmin}} \sum_{i=t-n+1}^t (y_i - (\beta_t^T X_i + \alpha_t))^2\end{aligned}$$

Régression linéaire (2)

- **Solution explicite :**

$$\hat{\beta}_t = (X^T X)^{-1} (X^T Y)$$

- **Sa matrice de covariance :**

$$\hat{\Omega}_{\hat{\beta}_t} = \hat{\sigma}_\varepsilon^2 (X^T X)^{-1}$$

- **Estimateur BLUE** (Best Linear Unbiased Estimator) : meilleur estimateur linéaire sans biais au sens de la minimisation de $\hat{\Omega}_{\hat{\beta}}$
- Hypothèse supplémentaire de normalité des résidus $\Rightarrow$ **test de student (t-test) de significativité des paramètres**

$$t_{\hat{\beta}_i} = \left| \frac{\hat{\beta}_i}{\hat{\sigma}_{\hat{\beta}_i}} \right| \rightarrow \text{loi de student à } n-k-1$$

- **Tests de stationnarité :**

- **in-sample** $\Rightarrow$ on fige l'estimation à la date t : $\hat{\beta} = \hat{\beta}_t$
- **out-sample** $\Rightarrow$ estimation glissante sur les fenêtres $[t - n + 1, t]$ $\Rightarrow$ résidus out-sample

$$\varepsilon_{t+1|t} = y_{t+1} - \hat{\beta}_t^T X_{t+1} + \hat{\alpha}_t$$

Régression linéaire généralisée

- Les hypothèses d'homoscédasticité et d'autocorrélation des résidus sont rarement vérifiées

$$\Omega_\varepsilon \neq \sigma_\varepsilon^2 I$$

- Il faut en tenir compte lors de l'estimation afin d'éviter des estimateurs biaisés et des t-tests fallacieux
- **L'estimateur BLUE** peut malgré tout s'écrire de façon explicite :

$$\hat{\beta}^{MCG} = (X^T \Omega_\varepsilon^{-1} X)^{-1} (X^T \Omega_\varepsilon^{-1} Y)$$

$$\hat{\Omega}_{\hat{\beta}^{MCG}} = (X^T \Omega_\varepsilon^{-1} X)^{-1}$$

- **Les 2 principaux estimateurs de Ω_ε :**
 - **HEC** (Heteroscedasticity Consistent Estimator) : correction de l'hétéroscédasticité
 - **HAC** (Heteroscedasticity and Autocorrelated Consistent Estimator) : correction de l'hétéroscédasticité et de l'autocorrélation

Régression pénalisée

- **Principe** : régression classique ou généralisée en ajoutant une fonction de pénalité sur les paramètres (discrimination)
- **Ridge Regression** :

- pénalisation de la régression par la norme L_2 des paramètres

$$\hat{\beta} = \underset{\beta, \alpha}{\operatorname{argmin}} \left\| Y - (\beta^T X + \alpha_t) \right\|_2^2 + \lambda \|\beta\|_2^2$$

- solution explicite :

$$\hat{\beta}^{\text{Ridge}} = (X^T X + \lambda I)^{-1} (X^T Y)$$

- **Lasso Regression** :

- pénalisation de la régression par la norme L_1 des paramètres

$$\hat{\beta}^{\text{Lasso}} = \underset{\beta, \alpha}{\operatorname{argmin}} \left\| Y - (\beta^T X + \alpha_t) \right\|_2^2 + \lambda \|\beta\|_1$$

- résolution du problème quadratique sous contrainte équivalent suivant :

$$\hat{\beta}^{\text{Lasso}} = \underset{\beta, \alpha}{\operatorname{argmin}} \left\| Y - (\beta^T X + \alpha_t) \right\|_2^2$$

$$\text{s.c} \quad \|\beta\|_1 \leq \lambda$$

Critères d'estimation alternatifs (1)

- En ometant α , on peut réécrire l'estimation MCO sur la fenêtre $[t - n + 1, t]$ comme suit :

$$\begin{aligned}\hat{\beta}_t^{MCO} &= \underset{\beta_t}{\operatorname{argmin}} \|\varepsilon(\beta_t)\|_2^2 \\ &= \underset{\beta_t}{\operatorname{argmin}} \sum_{i=t-n+1}^t (\varepsilon_i(\beta_t))^2\end{aligned}$$

- D'autres critères ont été proposés afin d'aboutir à des **estimations plus robustes**
- **Estimateur MAD** (Mean Absolute Deviation) :
 - minimise la norme L_1 des résidus :

$$\begin{aligned}\hat{\beta}_t^{MAD} &= \underset{\beta_t}{\operatorname{argmin}} \|\varepsilon(\beta_t)\|_1 \\ &= \underset{\beta_t}{\operatorname{argmin}} \sum_{i=t-n+1}^t |\varepsilon_i(\beta_t)|\end{aligned}$$

- estimateur plus robuste et discriminant que l'estimateur MCO
- pas de solution explicite $\Rightarrow$ résolution numérique du programme de

Critères d'estimation alternatifs (2)

- **Estimateur Theil-Sen :**

- **idée :** moyenner toutes les pentes empiriques sur la fenêtre d'estimation $[t - n + 1, t]$

$$\hat{\beta}_t^{TS} = \underset{\beta_t}{\operatorname{argmin}} \sum_{t-n+1 \leq i < j \leq t} \frac{1}{\|X_i - X_j\|_1} |\varepsilon_i(\beta_t) - \varepsilon_j(\beta_t)|$$

- **formulation alternative pour éviter l'optimisation numérique :**

- ① on choisit $1 \leq m \leq n$
- ② on forme selon la combinatoire, tous les sous-échantillons d'estimation possibles de taille m à partir de l'échantillon complet de taille n
- ③ sur chacun de ces sous-échantillons D_k , on calcule l'estimateur MCO :

$$\begin{aligned} \hat{\beta}_t^{(k)} &= \underset{\beta_t}{\operatorname{argmin}} \|\varepsilon_{D_k}(\beta_t)\|_2^2 \\ &= \underset{\beta_t}{\operatorname{argmin}} \sum_{i \in D_k} (\varepsilon_i(\beta_t))^2 \end{aligned}$$

- ④ l'estimateur de Theil-Sen est alors la médiane des estimateurs de tous ces sous-échantillons :

$$\hat{\beta}_t^{TS} = \operatorname{Median} \left\{ \hat{\beta}_t^{(k)} \right\}$$

Régression par filtre de Kalman

- **Estimation bayésienne :**

- on considère les paramètres β_t comme des variables cachées
- on réécrit la régression comme un **cas particulier d'un filtre de Kalman linéaire** :

$$y_t = \beta_t^T X_t + \alpha_t + \varepsilon_t$$

$$\beta_t = \beta_{t-1} + \eta_t$$

- **Principal avantage** : stabilité des β_t estimés au fil de l'eau

Régression SVM

- La regression SVM peut bien entendu être utilisée dans le cadre linéaire sans transformation spatiale
- **Frontière de décision** :

$$Y = f(X) = w^T X + b$$

- **Solution** : dépend toujours uniquement des vecteurs supports

$$f(X) = \sum_{i \in S} (a_i - \hat{a}_i) X_i^T X + b$$

- **Avantages** : qualités de robustesse et de stabilité de la regression sVM

Synthèse comparative

Critère	Stabilité	Robustesse	Discrimination
MCG		✓	
Ridge & Lasso			✓
MAD & Theil-Sen	✓		✓
Kalman	✓		
SVM	✓	✓	

Sommaire

- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires
- 3 Modèles linéaires
- 4 Cointégration**
- 5 Modèles dynamiques
- 6 Arbitrage statistique de volatilité
- 7 Arbitrage statistique de taux

Cointégration

- Principale innovation en économétrie de ces 30 dernières années
- Approche très souvent utilisée dans les stratégies Market Neutral ou de Pair Trading
- Introduction du concept suite à l'analyse approfondie des causes aboutissant à des régressions fallacieuses
- **Spurious Regression** :
 - **historiquement** : focalisation sur la violation des hypothèses classiques telles que l'homoscédasticité des résidus, l'indépendance des variables avec ce même résidu ou encore la significativité des paramètres
 - **cointegration** : on s'intéresse à présent aux conditions sur les variables regressées

Spurious Regression (1)

- Considérons une régression linéaire à une seule variable explicative :

$$y_t = \beta x_t + \alpha + \varepsilon_t$$

- Du point de vue des seules variables y_t et x_t on obtient typiquement une régression fallacieuse dans les 4 cas suivants :
 - ❶ $y_t = f_t^y + \varepsilon_t^y$ et $x_t = f_t^x + \varepsilon_t^x$ sont des **processus TS** (Trend Stationnary) et donc non-stationnaires et animés chacun de tendances déterministes de degrés différents (ex : f_t^y est linéaire en t et f_t^x quadratique).
 - ❷ $y_t = y_{t-1} + c^y + \varepsilon_t^y$ et $x_t = x_{t-1} + c^x + \varepsilon_t^x$ sont des **processus DS** (Differency Stationnary) et donc non-stationnaires et animés chacun de tendances stochastiques indépendantes.
 - ❸ y_t et x_t sont des processus animés chacun d'un **mix de processus DS et TS indépendants**
 - ❹ l'une des 2 variables y_t ou x_t est stationnaire et l'autre pas
- Dans chacun des cas ci-dessus, il n'y a aucune relation linéaire entre y_t et x_t

Spurious Regression (2)

- **Problèmes :**

- sur un échantillon (fini), on peut aboutir à une régression apparemment correcte (t-test valide, R^2 élevé...)
- avec ce type de processus, la statistique de Student est divergente $\Rightarrow$ t-test inefficace
- en pratique, la statistique de Durbin-Watson (DW) est souvent très faible $\Rightarrow$ forte autocorrélation des résidus

- **Signes d'une régression fallacieuse :** t-test valide, R^2 élevé mais DW très faible

- **Seuls cas où le cadre classique de la régression linéaire est valide :**

- y_t et x_t sont tous les deux des processus stationnaires
- y_t et x_t sont cointégrés
- Le premier cas est également un cas particulier de cointégration $CI(0,0)$
- **La notion de cointégration peut être vue comme une généralisation robuste de la régression linéaire**

Définitions et conditions de cointégration

- **Ordre d'intégration** : on dit qu'une série x_t est intégrée d'ordre d s'il faut la différencier d fois pour la stationnariser

$$x_t \rightarrow I(d)$$

- **Variables cointégrées** : 2 séries y_t et x_t sont dites cointégrées si les deux conditions suivantes sont vérifiées :

- ① y_t et x_t sont intégrés du même ordre d :

$$y_t \rightarrow I(d)$$

$$x_t \rightarrow I(d)$$

- ② il existe une combinaison linéaire permettant de se ramener à un ordre d'intégration $0 \leq d - b < d$:


$$\beta_1 y_t + \beta_2 x_t \rightarrow I(d - b)$$

- On note alors :

$$(y_t, x_t) \rightarrow CI(d, b)$$

- **Cas vectoriel** : $Y_t \rightarrow I(d)$ est dit cointégré si il existe un vecteur β tel que $\beta^T Y_t \rightarrow I(d - b) \Rightarrow Y_t \rightarrow CI(d, b)$.

Exemple de 2 variables cointégrées



Cadre financier

- Les prix sont typiquement $I(1)$: Unit Root $\Rightarrow$ les rendements sont typiquement $I(0)$ stationnaires
- Une somme de processus stationnaires n'est stationnaire que s'ils sont rigoureusement indépendants $\Rightarrow$ le residu d'une régression linéaire sur des rendements n'est donc pas nécessairement stationnaire
- Condition nécessaire de cointégration de séries de prix $I(1)$: doivent partager une tendance stochastique/déterministe de même ordre

$$\begin{aligned}y_t &= \beta^y z_t + \alpha^y + \varepsilon_t^y \\x_t &= \beta^x z_t + \alpha^x + \varepsilon_t^x\end{aligned}$$

- Les résidus ε_t^y et de ε_t^x doivent être :
 - ① stationnaires
 - ② indépendants i.e. ne pas comporter de relation stochastique secondaire autre que celle de z_t
- Tests de stationnarité sur $\beta^x y_t - \beta^y x_t$ incontournables !

Approche Engle & Granger (Etape 1)

- Les tendances déterministes et/ou stochastiques des deux séries y_t et x_t sont-elles du même ordre ?

$$y_t = f_t^y + z_t^y + \varepsilon_t$$

$$x_t = f_t^x + z_t^x + \varepsilon_t$$

- Degré (polynôme) des tendances déterministes f_t^y et f_t^x différent $\Rightarrow$ relation de cointégration impossible !**
- Degré d'intégration des 2 séries filtrées :

$$y_t - f_t^y \rightarrow I(d)$$

$$x_t - f_t^x \rightarrow I(d')$$

- Si $d \neq d' \Rightarrow$ relation de cointégration impossible !**

Approche Engle & Granger (Etape 2)

- **Cadre financier** : $y_t \rightarrow I(1)$ et $x_t \rightarrow I(1)$ avec tendance déterministe commune de degré 1

$$y_t = bt + \beta x_t + \alpha + \varepsilon_t$$

- **Tests de stationnarité sur les résidus** : Dickey-Fuller augmenté (DFA), Phillips-Perron (PP), KPSS...
- **Problème** : ces tests font l'hypothèse d'un estimateur MCO et que $y_t \rightarrow I(0)$ et $x_t \rightarrow I(0)$!
- **Solution** : générer par Monte-Carlo des tables de valeurs critiques spécifiques selon
 - le nombre d'observations
 - le nombre de variables explicatives
 - le degré commun d'intégration d entre les variables
 - la méthode d'estimation (MCO, MAD, Theil-Sen...)
- **Analyse** : approche simple mais tests de stationnarité peu efficaces

Approche ECM (Error Correction Model)

- Engle et Granger $\Rightarrow$ toute relation de cointégration peut être représentée par un modèle dynamique à correction d'erreurs
- **Relation de Cointégration = tendance long-terme + correction à court-terme**
- **Exemple** : $y_t \rightarrow I(1)$ et $x_t \rightarrow I(1)$

$$\Delta y_t = \alpha_1 \Delta x_t + \alpha_2 e_{t-1} + \varepsilon_t$$

- L'erreur e_t de la relation de long-terme estimée par régression linéaire :
 $y_t = \hat{\beta}x_t + \hat{\alpha} + e_t$
- **Conditions nécessaires de validité de la cointégration** :
 - le résidu ε_t doit être stationnaire
 - la constante α_2 doit être significativement négative (force suffisante de rappel à la tendance long-terme)
- **Analyse** : approche encore peu efficace et peu aisée à étendre au cas vectoriel

Approche VECM (Etapas 1 et 2)

- **Repose sur une représentation en VAR (Vector Auto-Regressive)** => modélise en bloc :
 - les différentes relations de cointégration
 - l'autocorrélation entre les différentes variables Y_t .
- **Etape 1** : teste si toutes les variables :
 - ont une tendance déterministe de même degré (constante, linéaire, quadratique...en temps)
 - sont intégrées selon le même ordre d
- **Etape 2** : critères usuels type AIC/BIC => retard p de la représentation $VAR(p)$ de Y_t de dimension k

$$Y_t = A_0 D_t + \sum_{i=1}^p A_i Y_{t-i} + \varepsilon_t$$

- D_t est la matrice représentant la tendance déterministe

Approche VECM (Etape 3)

- Au lieu d'essayer d'estimer directement le modèle $VAR(p)$, on réécrit ce modèle pour faire apparaître explicitement la relation VECM
- Variables financières $I(1) \Rightarrow$ on différencie 1 fois afin d'aboutir à des différences stationnaires :

$$\Delta Y_t = A_0 D'_t + \sum_{i=1}^{p-1} B_i \Delta Y_{t-i} + \Pi Y_{t-1} + \varepsilon_t$$

- **Relations de passage :**

$$B_i = \sum_{j=1}^i A_j - I \quad i \in [1, p-1]$$

$$\begin{cases} A_i = B_i - B_{i-1} & i \in [2, p-1] \\ A_1 = B_1 + \Pi + I \end{cases}$$

$$\Pi = \sum_{j=1}^p A_j - I$$

Approche VECM (Etape 4)

- **Théorème de représentation d'Engle et Granger selon le rang r de la matrice Π :**
 - $r = 0$: pas de relation de cointégration
 - $r = k$: toutes les variables sont $I(0) \Rightarrow$ estimation classique du modèle $VAR(p)$ OK
 - $0 < r < k$:
 - il existe r relations de cointégration et la représentation VECM est valide
 - la matrice Π peut s'écrire sous la forme $\Pi = \alpha\beta^T$
 - α est le vecteur de rappel du modèle vers l'équilibre long-terme
 - β la matrice contenant les coefficients des r relations de cointégration indépendantes
 - erreur de la relation de cointégration $e_t = \beta^T Y_t \Rightarrow$ le modèle VECM peut se réécrire :

$$\Delta Y_t = A_0 D_t' + \sum_{i=1}^{p-1} B_i \Delta Y_{t-i} + \alpha e_{t-1} + \varepsilon_t$$

Approche VECM (Etape 5 et 6)

- **Etape 5** : méthode d'estimation robuste par maximum de vraisemblance de VECM (Johanson)
- **Etape 6** : validation définitive des relations de cointégration
 - les résidus du VECM doivent être des bruits blancs (autocorrélation déjà filtrée par le modèle $VAR(p)$)
 - on ne garde alors que les relations de cointégration ayant une valeur de rappel α négative
- **Analyse** : l'approche VECM peut être vue comme une méthode robuste et efficiente d'estimation des modèles linéaires

Sommaire

- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires
- 3 Modèles linéaires
- 4 Cointégration
- 5 Modèles dynamiques**
- 6 Arbitrage statistique de volatilité
- 7 Arbitrage statistique de taux

Modèles de Pricing

- Usage exhaustif des modèles dynamiques dans l'industrie des dérivés
- Modèles markoviens => valorisation des dérivés plus aisée
- AOA => les prix sont des martingales sous Q (numéraire $B(t) = e^{\int_0^t r_s ds}$)

$$P_t^M(S_t, X_t, \lambda) = E_t^Q \left[e^{-\int_t^T r_s ds} \cdot \text{Payoff}(T) \right]$$

- **Notations :**

- S_t : vecteur des sous-jacents (variables observables)
- X_t : vecteur des variables d'état non-observables
- λ : vecteur des constantes du modèle
- Les constantes λ peuvent être :
 - spécifiées arbitrairement
 - estimés historiquement
 - **pour certaines d'entre elles notées X_t^C , calibrées sur d'autres dérivés liquides**

$$P_t^M(S_t, X_t^C, X_t, \lambda) \equiv P_t(S_t, O_t^C, X_t, \lambda)$$
$$O_t^C = O_t^M(S_t, X_t^C, X_t, \lambda)$$

Exemple : variantes du modèle Black-Scholes

- Dynamique de S_t sous Q :

$$\frac{dS_t}{S_t} = (r - m - d) dt + \sigma dW_t^S$$

- **Variante 1** : forme $P_t^M(S_t, \lambda)$

$$P_t^M = P_t^{BS}(S_t, \sigma)$$

- **Variante 2** : forme $P_t^M(S_t, X_t^C, \lambda)$

$$P_t^M = P_t^{BS}(S_t, \hat{\sigma}_t^{ATM, 1m}) \equiv P_t(S_t, C_t^{ATM, 1m})$$

$$C_t^{ATM, 1m} \equiv C_t^{BS}(S_t, \hat{\sigma}_t^{ATM, 1m})$$

- **Variante 3** : forme $P_t^M(S_t, X_t, \lambda)$

- payoff convexe $\Rightarrow$ définition d'une volatilité implicite $P_t^{market} \equiv P_t^{BS}(S_t, \hat{\sigma}_t)$
- dynamique de cette volatilité implicite : $d\hat{\sigma}_t = \mu_t^{\hat{\sigma}} + \nu_t^{\hat{\sigma}} dW_t^{\hat{\sigma}}$
- Modèle : $P_t^M = P_t^{BS}(S_t, \hat{\sigma}_{t|t-1}^f, \lambda^{\hat{\sigma}})$ et $\hat{\sigma}_{t|t-1}^f = E_{t-1}^Q[\hat{\sigma}_t]$

Modèles de Pricing et Arbitrage Statistique

- **Modèles sans variable de risque endogène**

$$Y_t = (P_t^{market}) = (P_t(S_t, O_t^C, \lambda)) + \epsilon_t$$

- Approche semblable à celle des market-makers
- Signaux de Relative Value également possibles par réplication dynamique
- **Modèles avec variables de risque endogènes**

$$Y_t = (P_t^{market}) = (P_t(S_t, O_t^C, X_t, \lambda)) + \epsilon_t$$

- En pratique :

$$Y_t = (P_t^{market}) = (P_t(S_t, O_t^C, X_{t|t-1}^f, \lambda)) + \epsilon_t$$

$$X_{t|t-1}^f = E_{t-1}^Q[X_t]$$

- Si $\dim(Y) = \dim(X) \Rightarrow$ stratégie de Relative Value impossible

Estimation des paramètres (1)

- Modèle général d'arbitrage statistique :

$$Y_t = (P_t^{market}) = (P_t(S_t, O_t^C, X_t, \lambda)) + \varepsilon_t$$

- **Estimation des paramètres λ des dynamiques sous la probabilité historique $\Rightarrow$ introduction d'une prime de risque incluse dans λ :**

$$\mu_t^S = (r_t - m_t - d_t) - \nu_t^S \sigma_t^S$$

- **Dynamiques en jeu sous la probabilité historique :**

$$\frac{dS_t}{S_t} = \mu_t^S dt + \sigma_t^S dW_t^S$$

$$\frac{dO_t^C}{O_t^C} = \mu_t^{O^C} dt + \sigma_t^{O^C} dW_t^{O^C}$$

$$dX_t = \mu_t^X dt + \sigma_t^X dW_t^X$$

Estimation des paramètres (2)

- **Equations de diffusion :**

$$\begin{aligned}S_t &= f_S(S_{t-\delta t}, \lambda) + \zeta_t^S \\O_t^C &= f_{O^C}(O_{t-\delta t}^C, \lambda) + \zeta_t^{O^C} \\X_t &= f_X(X_{t-\delta t}, \lambda) + \zeta_t^X\end{aligned}$$

- **Equations de mesure :**

$$\begin{aligned}Y_t &= P_t(S_t, O_t^C, X_t, \lambda) + \varepsilon_t \\S_t^{market} &= S_t + \varepsilon_t^S \\(O_t^C)^{market} &= O_t^C + \varepsilon_t^{O^C}\end{aligned}$$

- **Estimation par filtres de Kalman non-linéaires (EKF ou UKF précis à l'ordre 2) ou Particle Filter**

Synthèse de stratégies de Relative Value

- **Modèle :**

$$Y_t = P_t^{market} = P_t(S_t, O_t^C, \lambda) + \epsilon_t$$

$$O_t^C = O_t^M(S_t, X_t^C, \lambda)$$

- **Problème :** comment répliquer $P_t(S_t, O_t^C, \lambda)$?
- **Réponse :** par une stratégie de réplication/couverture dynamique

Market models P&L (1)

- **Portefeuille** Π_t^P :

$$\Pi_t^P = P_t - \text{Cash}_t^P$$

- **Trésorerie** Cash_t^P :

$$\text{Cash}_{t+\delta t}^P = \text{Cash}_t^P \cdot (1 + r_t \cdot \delta t)$$

- **P&L (comptable) entre t et $t + \delta t$:**

$$\begin{aligned}\delta \Pi_t^P &= [P_{t+\delta t}(S_t + \delta S_t, O_t^C + \delta O_t^C, \lambda) - P_t(S_t, O_t^C, \lambda)] - \delta \text{Cash}_t^P \\ &= [P_{t+\delta t}(S_t + \delta S_t, O_t^C + \delta O_t^C, \lambda) - P_t(S_t, O_t^C, \lambda)] - r_t P_t \delta t + r_t \Pi_t^P \delta t\end{aligned}$$

- **Dynamiques de S_t et O_t^C sous $\mathbf{Q}$:**

$$\frac{dS_t}{S_t} = (r_t - m_t - d_t) dt + \sigma_t^S dW_t^S$$

$$\frac{dO_t^C}{O_t^C} = r_t dt + \sigma_t^{O^C} dW_t^{O^C}$$

Market models P&L (2)

- **Développement limité à l'ordre 2 en δt , δS_t et δO_t^C** : on néglige les termes en $(\delta t)^2$, $\delta t \delta S_t$ et δO_t^C en pratique beaucoup plus faibles que les termes en δt , $(\delta S_t)^2$, $(\delta O_t^C)^2$ et $\delta S_t \delta O_t^C$

$$\begin{aligned}\delta \Pi_t^P &= r_t \Pi_t^P \delta t + \\ &\quad [\theta_t - rP_t] \delta t + \\ &\quad \Delta_t^S \delta S_t + \Delta_t^{O^C} \delta O_t^C + \\ &\quad \frac{1}{2} \Gamma_t^S (\delta S_t)^2 + \frac{1}{2} \Gamma_t^{O^C} (\delta O_t^C)^2 + \Gamma_t^{S, O^C} \delta S_t \delta O_t^C\end{aligned}$$

- **EDP de pricing vérifiée par le modèle** $\Rightarrow$ équivalence entre le théta corrigé du financement et les termes en deltas, gammas et cross-gamma

$$\begin{aligned}[\theta_t - rP_t] &= -\Delta_t^S ((r_t - m_t - d_t) S_t) - \Delta_t^{O^C} (r_t O_t^C) \\ &\quad - \frac{1}{2} \Gamma_t^S (\sigma_t^S S_t)^2 - \frac{1}{2} \Gamma_t^{O^C} (\sigma_t^{O^C} O_t^C)^2 - \Gamma_t^{S, O^C} (\sigma_t^S S_t \sigma_t^{O^C} O_t^C)\end{aligned}$$

Market models P&L (3)

- Réécriture du P&L :

$$\begin{aligned}\delta \Pi_t^P = & r_t \Pi_t^P \delta t + \\ & S_t \Delta_t^S \left[\frac{\delta S_t}{S_t} - (r_t - m_t - d_t) \delta t \right] + \\ & O_t^C \Delta_t^{O^C} \left[\frac{\delta O_t^C}{O_t^C} - r_t \delta t \right] + \\ & \frac{1}{2} S_t^2 \Gamma_t^S \left[\left(\frac{\delta S_t}{S_t} \right)^2 - (\sigma_t^S)^2 \right] + \\ & \frac{1}{2} (O_t^C)^2 \Gamma_t^{O^C} \left[\left(\frac{\delta O_t^C}{O_t^C} \right)^2 - (\sigma_t^{O^C})^2 \right] + \\ & S_t O_t^C \Gamma_t^{S, O^C} \left[\frac{\delta S_t \delta O_t^C}{S_t O_t^C} - \sigma_t^S \sigma_t^{O^C} \right]\end{aligned}$$

- **Analyse** : breakeven explicite pour chaque axe de risque, qui plus est indépendant de P_t

Couverture au 1er ordre (1)

- S_t et O_t^C sont les Instruments de couverture naturels pour les deltas Δ_t^S et $\Delta_t^{O^C}$
- **Sous-portefeuilles Π_t^S et $\Pi_t^{O^C}$:**

$$\Pi_t^S = S_t - Cash_t^S$$

$$\Pi_t^{O^C} = O_t^C - Cash_t^{O^C}$$

- **P&L $\delta\Pi_t^S$ et $\delta\Pi_t^{O^C}$:**

$$\delta\Pi_t^S = [\delta S_t - (r_t - m_t - d_t) S_t \delta t] + r_t \Pi_t^S \delta t$$

$$\delta\Pi_t^{O^C} = [\delta O_t^C - r_t O_t^C \delta t] + r_t \Pi_t^{O^C} \delta t$$

- **Portefeuille Π_t^{PH} couvert en Δ_t^S et $\Delta_t^{O^C}$:**

$$\Pi_t^{PH(1)} = \Pi_t^P - (\Delta_t^S) \Pi_t^S - (\Delta_t^{O^C}) \Pi_t^{O^C} - \left(\frac{RebalancingCost_t^{PH(1)}}{B_t} \right) B_t$$

$$= P_t - (\Delta_t^S) S_t - (\Delta_t^{O^C}) O_t^C - Cash_t^{PH(1)}$$

Couverture au 1er ordre (2)

- **La trésorerie $Cash_t^{PH}$ est plus complexe** $\Rightarrow$ coût de rebalancement de la couverture :

$$Cash_t^{PH(1)} = \left(\frac{P_t}{B_t} \right) B_t - \Delta_t^S \left(\frac{S_t}{B_t^S} \right) B_t^S - \Delta_0^{O^C} \left(\frac{O_t^C}{B_t} \right) B_t - \left(\frac{\Pi_t^{PH(1)}}{B_t} \right) B_t$$

- **P&L de la position couverte :**

$$\delta \Pi_t^{PH(1)} = \delta \Pi_t^P - \Delta_t^S \delta \Pi_t^S - \Delta_t^{O^C} \delta \Pi_t^{O^C} - r_t RebalancingCost_t^{PH(1)} \delta t$$

Couverture au 1er ordre (3)

- Au final :

$$\begin{aligned}\delta \Pi_t^{PH(1)} = & r_t \Pi_t^{PH(1)} \delta t + \\ & \frac{1}{2} \Gamma_t^S \left[(\delta S_t)^2 - (\sigma_t^S S_t)^2 \delta t \right] + \\ & \frac{1}{2} \Gamma_t^{O^c} \left[(\delta O_t^c)^2 - (\sigma_t^{O^c} O_t^c)^2 \delta t \right] + \\ & \Gamma_t^{S, O^c} \left[\delta S_t \delta O_t^c - (\sigma_t^S S_t \sigma_t^{O^c} O_t^c) \delta t \right]\end{aligned}$$

Couverture au 2eme ordre (1)

- 3 nouveaux instruments nécessaires $G_t^1 = G_t^1(S_t, O_t^C, \lambda)$, $G_t^2 = G_t^2(S_t, O_t^C, \lambda)$, $G_t^3 = G_t^3(S_t, O_t^C, \lambda)$ pour couvrir les 3 gammas/cross-gammas
- **Sous-portefeuilles associés :**

$$\Pi_t^{G^i} = G_t^i - Cash_t^{G^i}$$

- **Sous-portefeuilles couverts :** couverture au 1er et au 2eme ordres indépendants !

$$\begin{aligned}\Pi_t^{G^i H(1)} &= \Pi_t^{G^i} - \left(\frac{dG_t^i}{dS_t} \right) \Pi_t^S - \left(\frac{dG_t^i}{dO_t^C} \right) \Pi_t^{O^C} - \left(\frac{RebalancingCost_t^{G^i H(1)}}{B_t} \right) B_t \\ &= G_t^i - \left(\frac{dG_t^i}{dS_t} \right) S_t - \left(\frac{dG_t^i}{dO_t^C} \right) O_t^C - Cash_t^{G^i H(1)}\end{aligned}$$

Couverture au 2eme ordre (2)

- Leur P&L :

$$\begin{aligned}\delta \Pi_t^{G^i H(1)} &= r_t \Pi_t^{G^i H(1)} \delta t + \\ &\quad \frac{1}{2} \frac{d^2 G_t^i}{dS_t^2} \left[(\delta S_t)^2 - (\sigma_t^S S_t)^2 \delta t \right] + \\ &\quad \frac{1}{2} \frac{d^2 G_t^i}{d(O_t^C)^2} \left[(\delta O_t^C)^2 - (\sigma_t^{O^C} O_t^C)^2 \delta t \right] + \\ &\quad \frac{d^2 G_t^i}{dS_t dO_t^C} \left[\delta S_t \delta O_t^C - (\sigma_t^S S_t \sigma_t^{O^C} O_t^C) \delta t \right] -\end{aligned}$$

Couverture au 2eme ordre (3)

- Couverture d'un seul gamma/cross-gamma parmi les 3 :

$$HR_t^1 = \frac{\Gamma_t^S}{\frac{d^2 G_t^i}{dS_t^2}}$$

$$HR_t^2 = \frac{\Gamma_t^{O^C}}{\frac{d^2 G_t^i}{d(O_t^C)^2}}$$

$$HR_t^3 = \frac{\Gamma_t^{S, O^C}}{\frac{d^2 G_t^i}{dS_t dO_t^C}}$$

- **Problème** : modification de l'exposition sur les 2 autres gamma/cross-gamma

Couverture au 2eme ordre (4)

- Couverture en bloc sur les 3 gamma/cross-gamma :

$$\begin{pmatrix} \frac{d^2 G_t^1}{dS_t^2} & \frac{d^2 G_t^1}{d(O_t^C)^2} & \frac{d^2 G_t^1}{dS_t dO_t^C} \\ \frac{d^2 G_t^2}{dS_t^2} & \frac{d^2 G_t^2}{d(O_t^C)^2} & \frac{d^2 G_t^2}{dS_t dO_t^C} \\ \frac{d^2 G_t^3}{dS_t^2} & \frac{d^2 G_t^3}{d(O_t^C)^2} & \frac{d^2 G_t^3}{dS_t dO_t^C} \end{pmatrix} \begin{pmatrix} HR_t^1 \\ HR_t^2 \\ HR_t^3 \end{pmatrix} = \begin{pmatrix} \Gamma_t^S \\ \Gamma_t^{O^C} \\ \Gamma_t^{S, O^C} \end{pmatrix}$$

Couverture au 2eme ordre (5)

- **Portefeuille couvert à l'ordre 2 :**

$$\begin{aligned}\Pi_t^{PH(2)} &= \Pi_t^P - (\Delta_t^S) \Pi_t^S - (\Delta_t^{O^C}) \Pi_t^{O^C} - \sum_{i=1}^3 (HR_t^i) \Pi_t^{G^i H(1)} - \left(\frac{RC_t^{PH(2)}}{B_t} \right) B_t \\ &= P_t - (\Delta_t^S) S_t - (\Delta_t^{O^C}) O_t^C - \sum_{i=1}^3 (HR_t^i) \Pi_t^{G^i H(1)} - Cash_t^{PH(2)}\end{aligned}$$

- **Son PnL à l'ordre 2 est alors tout simplement une martingale :**

$$\delta \Pi_t^{PH(2)} \approx r_t \Pi_t^{PH(2)} \delta t$$

Réplication

- Couverture au 1er et 2eme rendu => **le PNL du portefeuille couvert est une martingale de valeur nulle** :

$$\Pi_t^{PH(2)} = \Pi_0^{PH(2)} B_t = 0$$

- Prix du dérivé répliqué dynamiquement par rebalancement de la couverture :

$$P_t \approx \Delta_t^S S_t + \Delta_t^S O_t^C + \sum_{i=1}^3 HR_t^i \Pi_t^{G^i H(1)} + Cash_t^{PH(2)}$$

Couverture dynamique : problèmes pratiques (1)

- Réalisation pratique d'une couverture dynamique théorique => biais et coûts supplémentaires
- **Coûts de rebalancement** : couverture discrète impliquant des coûts liés aux fourchettes Bid-Ask et frais de transaction divers => rebalancer parcimonieusement
- **Schémas de rebalancement usuels** :
 - Time Based
 - Move Based
- **Un Market Maker ne couvre que son inventaire résiduel** => frais d'échelle !
- La couverture au deuxième ordre implique souvent l'utilisation d'instruments peu liquides et donc coûteux à rebalancer => **préférer des modèles plus efficaces où la couverture au premier ordre est suffisante**

Couverture dynamique : problèmes pratiques (2)

- **Risque de modèle** : capacité du modèle à modéliser correctement tous les risques associés au produit
- **Un bon modèle de Pricing est avant tout un bon modèle de hedging**
- **Modèle idéal** :
 - estimation correcte des lois des principaux axes de risque en jeu (pas de terme correctif)
 - formulation ne dépendant que de variables tradables (Market Model) (pas de PNL leakage)
 - une couverture à l'ordre 1 suffit la plupart du temps (limitation des coûts)

Formulation du résidu (1)

- En remarquant :

$$\begin{aligned}P_{t+\delta t}^f &= P_{t+\delta t|t} \left(S_{t+\delta t|t}, O_{t+\delta t|t}^C, X_{t+\delta t|t}, \lambda \right) \\&= E_t \left[P_{t+\delta t} \left(S_{t+\delta t}, O_{t+\delta t}^C, X_{t+\delta t}, \lambda \right) \right]\end{aligned}$$

- La différentielle du prix prédit par le modèle s'écrit donc simplement :

$$\delta P_t^f = P_{t+\delta t}^f - P_t = \mu_t P_t \delta t$$

- Le résidu peut alors s'exprimer comme la somme des sensibilités aux différents axes de risque
- **La stationnarité du résidu dépend donc largement de la qualité d'estimation du modèle**
- Les drifts sont habituellement difficiles à estimer => modèle sur le portefeuille couvert au 1er ordre

$$\left(\Pi_t^{PH(1)} \right)^{market} = \Pi_t^{PH(1)} \left(S_t, O_t^C, X_t, \lambda \right) + \varepsilon_t$$

Formulation du résidu (2)

- Résidu d'un modèle dynamique d'arbitrage statistique :

$$\begin{aligned}\varepsilon_t = & \Delta_t^S [\delta S_t - \mu_t^S S_t \delta t] + \\ & \Delta_t^{O^c} [\delta O_t^c - \mu_t^{O^c} O_t^c \delta t] + \\ & \Delta_t^X [\delta O_t^c - \mu_t^X \delta t] + \\ & \frac{1}{2} \Gamma_t^S [(\delta S_t)^2 - (\sigma_t^S S_t)^2 \delta t] + \\ & \frac{1}{2} \Gamma_t^{O^c} [(\delta O_t^c)^2 - (\sigma_t^{O^c} O_t^c)^2 \delta t] + \\ & \frac{1}{2} \Gamma_t^X [(\delta S_t)^2 - (\sigma_t^X)^2 \delta t] + \\ & \Gamma_t^{S,O^c} [\delta S_t \delta O_t^c - (\sigma_t^S S_t \sigma_t^{O^c} O_t^c) \delta t] + \\ & \Gamma_t^{S,X} [\delta S_t \delta X_t - (\sigma_t^S S_t \sigma_t^X) \delta t] + \\ & \Gamma_t^{X,O^c} [\delta X_t \delta O_t^c - (\sigma_t^X \sigma_t^{O^c} O_t^c) \delta t]\end{aligned}$$

Sommaire

- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires
- 3 Modèles linéaires
- 4 Cointégration
- 5 Modèles dynamiques
- 6 Arbitrage statistique de volatilité**
- 7 Arbitrage statistique de taux

Sommaire

- 1 Arbitrages statiques et statistiques
- 2 Modèles non-linéaires
- 3 Modèles linéaires
- 4 Cointégration
- 5 Modèles dynamiques
- 6 Arbitrage statistique de volatilité
- 7 Arbitrage statistique de taux