

Quatrième partie

Trading Haute fréquence

22 Microstructure de marché

THF = Trading algorithmique + Trading quantitatif + vitesse

22.1 Fragmentation des marchés électroniques

- Ouverture à la concurrence des places boursières : MiFID (2007) en Europe et Reg NMS (2005) aux USA
- **Reg NMS** : centralisation et consolidation des carnets d'ordres => NBBO (National Best Bid-Offer)
- **MI FID** : concurrence des prix entre plateformes de trading hétérogènes => MTFs (Multilaterals Trading Facility) + SOR (Smart Order Routing) chez les brokers
- **Conséquences** :
 - Amélioration de la qualité de services (vitesse, différents types d'ordres...)
 - Baisse des coûts de transaction et amélioration de la liquidité
 - Innovations : nouveaux types d'ordres (hidden ordres, pegged orders...), nouvelles règles d'appariements, dark pools...
 - Boom du Trading Haute Fréquence (auparavant quelques pionniers contraints par les limites techniques et réglementaires)
- **Ancienne microstructure** : 3 niveaux (Buy-Side - Sell-Side - Exchanges)
- **Nouvelle microstructure** : réseau complexe d'intervenants
- Places historiques trop lentes => Nouvelles places alternatives plus rapides (Turquoise, BATS, CHI-X...)
- Augmentation de la complexité + coût technologique + THF => « **selection adverse** » des traders lents => **Dark Pools**
- **Dark Pools** : anonymat des ordres (montant et niveau)
- Optimisation des coûts fixes + concurrence => fusion des plateformes (LSE + Turquoise...)
- Les Dark Pools encore marginales (2-3% des transactions) sont appelées à prendre de l'importance pour contrebalancer cette consolidation du secteur




FIGURE 22.1 – Ancienne microstructure




FIGURE 22.2 – Nouvelle microstructure

22.2 Marchés électroniques

- **Techno** : télégraphe => téléphone => computers & networks => optic fibers & microwaves (ultra low latency)
- Post crisis 2007-2008 => liquidity issue => remplacement des traders par du trading algo => rise of HFT & marchés électroniques
- Services spécifiques fournis au HF : co-location et canaux de communication à faible latence (micro-ondes)
- Plus gros poste de revenus aujourd'hui = services HF => implications
 - fournisseurs de services technologiques
 - problèmes de conflits d'intérêts potentiels

22.3 Carnet d'ordres

- **Règles de priorité** : Prix - FIFO
- **Types d'ordres** : Limit Order - Market Order - Cancellation Order - Hidden Order - Pegged Order - Iceberg Order...
- **Vocabulaire** : at-the-touch + walk the LOB + cross the spread Hidden liquidity
- **Tick size**



FIGURE 22.3 – Exchange




FIGURE 22.4 – Carnet d’ordres

22.4 Acteurs et activités

Toutes les activités LF des marchés liquides ont été transposées en HF => transformation de la chaîne de valeur (THF > Trading On Floor > Trading Off Floor)

Activités

- **Brokerage** : exécution optimale des ordres des clients (optimisation de toute la structure de coût (slippage))
- **Market Making** : fournisseurs de liquidité => Limit Orders
- **Trading/Arbitrage** : consommateurs de liquidité => Market Orders
- **Gaming** : manipulation de marché => Limit Order + Market Orders + Cancellation Orders

Typologie des acteurs

- Market makers
- Noise trader (pas d'information) => Execution-brokerage + hedging + règles de rebalancement chez les Funds managers + price manipulation
- Informed traders (informés) => Trading/investment + arbitrageurs (HF, IB, CTA...)

22.5 Régulation

Points Positifs :

- augmentation de la liquidité
- pas de signes d'augmentation globale de la volatilité
- intégration plus rapide de l'information dans les prix
- baisse des coûts de transaction
- amélioration de la qualité de service (moteurs d'appariement à la microseconde)
- baisse du tick size sur la plupart des marchés dû à la compétition

Points Négatifs :

- « Flashcrashes » : risque systémique pendant de courtes périodes et sans justification économique dus à des effets de contagion algorithmiques incontrôlables
- manipulations de marché très difficiles à détecter
- conflits d'intérêts possibles chez les exchanges au profit des traders HF au détriment des traders plus lents

- surinvestissement technologique et inflation des coûts dû à la complexité croissante
- activité réduite chez les traders plus lents par peur d'être arbitrés par les traders HF (pb : ils apportent une liquidité structurelle Long Terme)

Principales problématiques de régulation en cours :

- **Valeur optimale du Tick Size** : trop faible, il favorise le bruit de microstructure, trop élevé, il empêche l'incorporation rapide de l'information dans les prix (baisse de la liquidité)
- **Vitesse optimale de trading** : pour les mêmes raisons que pour le Tick Size
- **Capitaux propres minimaux pour les acteurs Haute Fréquence** : empêcher la contagion éventuelle de faillites en cascade
- **Appels de marge en cours de journée**
- **Détection des manipulations de marché en HF**

23 Données haute-fréquences

23.1 Faits stylisés intraday

23.1.1 Indicateurs clefs

Les principaux indicateurs décrivant les données et l'activité intradays sont les suivants :

- **Volume** : nombre de transactions effectuées
- **Volatility**
- **Market Depth** : somme de la taille de tous les LOs dans le carnet d'ordres
- **Net Order Flow** : $V_t^a - V_t^b$
- **Volume Imbalance** : $\frac{V_t^a - V_t^b}{V_t^a + V_t^b}$
- **Spread Bid-Ask** : $P_t^a - P_t^b$
- **Mid-Price** : $\frac{1}{2} (P_t^a + P_t^b)$
- **Micro-Price** : $\frac{V_t^b}{V_t^a + V_t^b} P_t^a + \frac{V_t^a}{V_t^a + V_t^b} P_t^b$

23.1.2 Saisonnalité

Les données intraday ont une très forte composante saisonnière¹ essentiellement dues aux ouvertures et fermeture de marché. La volatilité et le volume de transactions ont typiquement une forme en U (U-shaped) :

On peut constater trois types d'évènements ayant un impact significatifs sur les données intraday :

1. **L'ouverture des marchés** : période de forte activité car l'information depuis la dernière cloture doit être intégrée aux prix. L'effet est donc d'autant plus important le lundi ou à la suite de jours fériés.

¹Le processus de désaisonnalisation de ces données pour l'estimation correcte des modèles HF, suppose donc une base de données exhaustives de tous les évènements, jours spéciaux affectant les contrats traités.




FIGURE 23.1 – Volumes Intraday




FIGURE 23.2 – Volatilité Intraday




FIGURE 23.3 – Activité sur les principaux marchés

2. **La fermeture des marchés** : la cloture de marché génère habituellement plus d'activité encore du fait essentiellement du mécanisme d'enchère (closing auction) pour fixer le Closing Price, valeur clef pour le calcul des NAV et autres positions des portefeuilles. De plus il faut préparer l'overnight et l'incertitude liée à la tombée d'informations importantes lors de la fermeture des marchés.. L'activité est également d'autant plus importante le vendredi et à la veille de jours fériés.
3. **Evènements ou informations importantes** : Corporate Actions (dividendes, coupons, clauses activées...), chiffres macros, maturité de produits dérivés importants, évènements géopolitiques majeurs...

Evidemment, les phénomènes de réouverture de marchés à la suite d'autres peuvent amplifier les activités constatées habituellement :

Autre quantité importante ayant une forte composante saisonnière : la fourchette bid-ask ψ_t :

La fourchette bid-ask dépend bien évidemment du tick size δ mais également très fortement de la volatilité σ_t . Sur les marchés Equity, on constate souvent la relation suivante où N est le nombre de transactions par jour.




FIGURE 23.4 – Spreads Bid-Ask Intraday

$$\psi_t \simeq \eta \delta \propto \frac{\sigma_t}{\sqrt{N}} + \phi$$

23.2 Impact des échelles de temps

À échelles de temps élevées, les prix se comportent comme des processus auto-similaires. On a alors naturellement tenté de les modéliser par des semi-martingales d'Itô, des mouvements browniens fractionnaires (coefficient de Hurst constant) ou multi-fractionnaires (le coefficient de Hurst $H(x)$ n'est plus constant) ou encore des modèles fractales. Malheureusement, à échelles de temps faibles, les prix ne se comportent plus de la sorte et deviennent discrets et asynchrones.

On peut schématiquement isoler 3 grandes échelles de temps requérant chacune une modélisation spécifique :

- **Microscopique (UHF/THF : $\Delta t < 1s$)** : microstructure du carnet d'ordres, les quantités et les prix sont constants par morceaux
- **Mesoscopique (HF : $1ms < \Delta t < 100s$)** : les quantités du carnet d'ordre sont des processus continus mais les prix constants par morceaux
- **Macroscopique (LF : $\Delta t > 100s$)** : les prix suivent une martingale d'Itô

L'idée serait de construire des modèles permettant de concilier ces trois échelles (microscopiques et macroscopiques). Le trading haute-fréquence se concentre en tout




FIGURE 23.5 – Données par heure pendant 1 an




FIGURE 23.6 – Une donnée par seconde pendant 1 journée




FIGURE 23.7 – Une donnée par seconde pendant 1 heure




FIGURE 23.8 – Market Impact d'un Buy MO

cas plus essentiellement sur la modélisation des prix à l'échelle mésoscopique (trading optimal) et favorise donc des modèles spécifiques à cette échelle de fréquence. Néanmoins, pour certaines problématiques spécifiques comme nous le verrons, une approche alternative consiste à utiliser des modèles microscopiques du carnet d'ordres pour modéliser des effets à des échelles plus élevées. Nous verrons notamment ce type de modèles dans le chapitre consacré à la modélisation du carnet d'ordres. Plus rarement, certaines approches partent de modèles diffusifs macroscopiques corrigés pour tenir du bruit de microstructure à plus basse échelle de temps (voir le chapitre consacré à l'estimation haute-fréquence).

Pour terminer, notons le comportement particulier de la volatilité et de la corrélation selon l'échelle de temps considérée. Typiquement, on observe les faits stylisés suivant et sur lesquels nous reviendront dans un chapitre ultérieur consacré aux problématiques spécifiques de l'estimation de ces indicateurs en haute-fréquence :

- La variance/volatilité réalisée augmente très rapidement avec la fréquence à partir de son niveau stable à échelles de temps longues.
- La corrélation au contraire décroît rapidement avec la fréquence à partir de son niveau stable à échelles de temps longues (Epps effect).

23.3 Market impact

A l'échelle mésoscopique, on observe que les MOs soumis au sein du carnet d'ordre conduisent à des mouvements du prix globalement dans le sens de l'ordre : c'est le Market impact.

C'est un phénomène clef dans la formation des prix et nous y reviendrons plus en détail dans un chapitre dédié spécifiquement afin de donner quelques clefs de compréhension du phénomène. Ceci étant naturellement est une source de coût importante lors de l'exécution d'un ordre, surtout si il d'une taille importante, il convient d'en

avoir une modélisation adéquate dans la formalisation des problèmes de trading optimal. On peut clairement identifier quatre phases distinctes (cas d'un Buy MO) dans l'ordre suivant :

1. Transient Impact : de forme concave et croissant jusqu'à un maximum
2. Temporary Impact : correspond au maximum du mouvement de prix observé suite à l'exécution de l'ordre
3. Decay Impact : on a ensuite une phase d'atténuation jusqu'à un état stable correspondant au Permanent Impact
4. Permanent Impact : correspond à l'impact final et stable de l'exécution de l'ordre

Les premières études statistiques ont permis d'aboutir à une fonction croissante du volume v_t exécuté :

$$MI_t \propto \sigma \sqrt{\frac{v_t}{V_t}} T^{-0.2}$$

23.4 Carnet d'ordres

Voici en vrac, les principaux faits stylisés observés sur les carnets d'ordres :

- L'analyse empirique des temps d'arrivée des ordres montrent qu'ils ne suivent pas un processus de Poisson mais plutôt une distribution type Weibull ou q-exponentielle (Weibull). Ceci oriente donc vers une modélisation par processus de Hawkes.
- Le volume des ordres suit plutôt une loi puissance mais il n'y a pas de consensus sur ce point.
- La durée de vie pour un ordre limite (LO) suit plutôt une loi puissance qu'il soit exécuté ou annulé.
- On constate un fort retour à la moyenne du spread liée essentiellement aux activités de Market Making lorsque le spread s'écarte (le marché fournit de la liquidité) et au Market Taking lorsque le spread devient plus étroit (le marché prend la liquidité en excès).
- On observe un large clustering (autocorrélation positive) des différents types d'ordres (MOs et LOs) et un fort impact positif sur les ordres LOs en cas de forte arrivée des ordres MOs (market making). Rq : le contraire n'est pas vrai, pas d'impact des LOs sur les MOs.
- Empiriquement, on observe la plupart du temps des formes en « bosses » (hump) sur la distribution des volumes au sein du carnet d'ordre, que ce soit sur la partie ask ou la partie bid, comme dans la figure suivante :




FIGURE 23.9 – Carnet d'ordres : distribution des volumes

24 Stratégies de trading

Tous les métiers présents en basse fréquence sont présents en haute-fréquence : trading directionnel et arbitrage statistique, hedging, Market Making, Arbitrage, exécution d'ordres (brokerage)... Dans cette partie, nous parlerons plus spécifiquement des stratégies de trading, les autres métiers seront abordés dans les chapitres suivants.

24.1 Classification

Jusqu'à un certain niveau de fréquences et échelle de temps (environ 1 minute) les modèles et approches classiques utilisées en basse fréquence pour le trading directionnel et l'arbitrage statistique, restent valables et sont appliquées avec des modifications mineures en tenant compte des caractéristiques spécifiques, en particulier la saisonnalité, des données Intraday (voir chapitre ci-après). A plus haute fréquence, les prix ne suivent plus une diffusion brownienne, du fait du Tick Size mais aussi de la baisse des transactions en même temps que l'échelle de temps. D'autres stratégies spécifiques sont alors mises en oeuvre et que nous pouvons classer comme suit :

- **News trading** : l'idée est de traiter le plus rapidement possible, grâce à une infrastructure optimisée pour cela, les informations économiques et financières clefs conduisant à des mouvements importants sur les marchés. La date de tombée de l'information peut être aléatoire (information géopolitique majeure...) ou fixée à l'avance comme la tombée de chiffres économiques majeurs.
- **Arbitrage du carnet d'ordres** : l'idée est de tirer partie de l'effet prédictif du Volume Imbalance (le secret le moins bien gardé du THF) ou de propriétés habituelles observées sur les différentes limites de prix ainsi que leurs volumes constatés au sein du carnet d'ordres (premières, secondes, troisièmes...). Concrètement, cela se matérialise en règles de trading très simples s'appuyant sur des indicateurs techniques spécifiques, simples ou avancés comme la probabilité de hausse compte tenu de l'état actuel du carnet d'ordre et qui suppose une modélisation de ce dernier (voir chapitre dédié)
- **Scalping/Structural strategies** (cf. Haim Bodek et son fonds) : cette famille de stratégies essaient de tirer partie des subtilités techniques et structurelles propre à chaque marché électronique. Elles tirent leur nom du "scalping" des micro-spreads, que ces traders ont opérés au tout début du haute-fréquence. Il s'agissait simplement de réaliser le spread bid-ask le plus rapidement possible avant que le prix ne bouge. Quasi-impossible aujourd'hui à réaliser avec la co-location, ce type de traders se sont orientés vers d'autres stratégies : Latency

arbitrage, Rebate arbitrage, Exchange Microstructure Arbitrage (utilisation des divers types d'ordres possibles, en particulier les ordres atypiques proposés par certains échanges, et des subtilités techniques du matching d'ordres au sein du moteur d'appariement). La clef pour ce type de stratégies est d'être toujours bien placé au sein du carnet d'ordre pour que l'entrée et la sortie des trades réalisés se fassent quasiment sûrement et le plus rapidement possible.

- **Liquidity detection (Pinging/Sniping/Sniffing/Phising)** : sortes de techniques de hammeçonnage (cf. informatique) permettant de façon détournée, de détecter les intentions des grands acteurs du marché et ensuite d'activer des tactiques de Front-Running. Par exemple, en postant de petits ordres au début du carnet afin de connaître les types de liquidité recherchées par les investisseurs institutionnels qui découpent leurs ordres afin de ne pas subir le Market Impact. On tire ensuite partie de cette information en asséchant la liquidité qu'ils recherchent au sein du carnet d'ordres pour ensuite la reposer en leur faisant évidemment payer plus cher.
- **Manipulation de marché** :
 - **Quote Stuffing** : l'idée est de désorienter les différents acteurs avec de la fausse information (bruit) en soumettant un torrent de LOs (Bid, ask ou les deux simultanément) durant une très courte période (2s en moyenne) et qui sont annulés très rapidement par la suite. C'est une technique malveillante très similaire à une attaque DDoS en informatique car cela ralentit l'appariement des ordres "réels" et induit en erreur le restant des acteurs en les conduisant à opérer à des stratégies sous-optimales. un objectif plus concret à cette manœuvre peut consister aussi à manipuler le midpoint afin d'obtenir des prix plus favorables sur les Dark Pools. C'est une pratique assez courante (en moyenne entre 50 et 60 fois par jour sur certains segments de marché).
 - **Moment Ignition** : le but est d'enclencher un gros mouvement sur les prix dans une direction donnée, en déposant des LOs à des volumes/tailles plus élevés que d'habitude afin de créer un effet moutonnier dans la direction voulue. Une fois le mouvement de hausse (ou de baisse) arrivé à sa fin, la pose est débouclée pour prendre les profits et le prix reviennent alors au point de départ (avec des volumes plus faibles néanmoins). C'est une stratégie beaucoup moins fréquente que le "Quote Stuffing" (1 à 2 fois par jours sur les actions liquides)
 - **Layering/Order Fade** : l'idée est de créer une fausse impression de liquidité dans une direction donnée en postant des LOs à différents niveaux de prix étalés assez loin dans le carnet d'ordres (Market Depth augmentée artificiellement). Par la suite, ces ordres seront annulés juste avant qu'ils ne puissent être exécutés. C'est donc une façon artificielle de manipuler les prix avec un leurre.




FIGURE 24.1 – Stratégies de trading HF

Toutes ces stratégies créent un contexte de War Game algorithmique (camouflage, leurre, manipulation, ordres agressifs, anticipations, course technologique. La vitesse est cruciale afin d’exploiter les opportunités à très courte durée et où le plus rapide “remporte tout”.

24.2 Mise en oeuvre

Quelque soit le type de stratégie de trading, elle doit au préalable être backtestée avant d’être mise en production. Le problème, c’est le carnet d’ordre se modifie dynamiquement en fonction des ordres (et les types d’ordres) qui lui sont soumis. Un backtesting « statique » ne peut donc être vraiment concluant. L’idéal est donc d’avoir à sa disposition un moteur robuste de simulation du carnet d’ordre à l’aide duquel on peut effectuer des simulations Monte-Carlo qui serviront ainsi à tester les stratégies de façon dynamiques et surtout beaucoup plus réaliste. Avoir un modèle réaliste et robuste du carnet d’ordre, bien évidemment estimés sur données réelles, est donc un outil important dans le processus de développement de stratégies Haute-Fréquence. Nous aborderons ce problème dans le chapitre suivant.

Passons à présent à l'infrastructure technique. C'est un problème crucial et complexe. Une architecture type Principal-Agent est souvent employé avec deux niveaux aux tâches bien spécifiques :

- **Niveau stratégique** : ce niveau est chargé de calculer au niveau mesoscopique des courbes de trading optimales ainsi que leurs enveloppes de confiance, estimer des paramètres de modèles...Une autre tâche importante à ce niveau est de transmettre ces courbes optimales ou paramètres estimés ou encore des bouts de codes aux trading robots en co-location près des moteurs d'appariement de toutes les bourses à travers le monde (lit pools et dark pools) sur lequel ces stratégies traitent. Le problème de la synchronisation des ordres se pose alors également immédiatement, et c'est également à ce niveau de le gérer avec une couche logicielle spécifique. Enfin, ce niveau reçoit des informations en retour de ces robots lui permettant de réaliser dynamiquement des ajustements sur la stratégie globale.
- **Niveau Tactique** : cette couche correspond aux trading-robots situés en co-location près des moteur d'appariements des carnets d'ordres. Ils sont censés exécuter, de la meilleure façon possible, mais au niveau microscopique cette fois-ci, les courbes de trading optimales ou plus généralement les algorithmes que lui a envoyé le niveau stratégique. Pour être le plus rapide possible, En cas de courbes de trading, le robot à généralement

Avec le mécanisme de co-location, la course à la latence au niveau réseau a bien évidemment perdu en intérêt mais reste néanmoins primordiale pour réagir le plus rapidement possible dans le pilotage du réseau de trading robots.

Néanmoins, pour les trading robots en co-location mais aussi au niveau de la couche stratégique et pour gagner en latence et efficience, on utilise très souvent des cartes reprogrammables type FPGA :




FIGURE 24.2 – Architecture d’un système de trading Haute-Fréquence




FIGURE 24.3 – Latence entre les différentes bourses de la planète




FIGURE 24.4 – Carte FPGA

25 Modélisation du carnet d'ordre

On se place ici dans un cadre de modélisation des prix UHF/THF où la granularité au sein du carnet d'ordres tient une place centrale. Les premières approches ont été le fait de physiciens venus à la finance (econophysiciens) à la fin des années 90 qui appliquèrent des paradigmes physiques similaires en considérant le mécanisme du carnet d'ordres est semblable à celui d'évaporation-absorption de particules (ordres). Malheureusement, ce type de modèles ne permet pas de garantir la stabilité du carnet d'ordres autrement dit son ergodicité (i.e. qu'il converge avec n vers une distribution indépendante du temps). De plus plusieurs faits stylisés du carnet d'ordres ne peuvent être retrouvés et la volatilité du prix théorique converge vers l'infini à échelle de temps longues et non vers un mouvement brownien à volatilité finie.

On s'est alors concentré sur des modèles permettant d'aboutir non seulement à ces deux aspects clefs (ergodicité des distributions et convergence des prix vers un mouvement brownien à échelles de temps longues) permettant de relier de façon cohérente la microstructure de marché et son comportement diffusif (brownien) à basse fréquences, mais aussi de retrouver les faits stylisés observés sur les carnets d'ordres. On s'est alors orienté vers des modèles représentant le carnet d'ordres comme une file d'attente multidimensionnelle comme suit :

$$LOB(t) = X_t = (B(t), A(t)) = (b_K(t), \dots, b_1(t), a_1(t), \dots, a_K(t))$$

Les quantités $(a_k(t))_{k \in [1, K]}$ et $(b_k(t))_{k \in [1, K]}$ représentent respectivement à la date t , les quantités d'ordres LOs postées de part et d'autre des meilleures cotations ask et bid, et correspondant à une grille de prix espacés du même tick size de part et d'autre du carnet d'ordres. Ainsi, $a_k(t)$ correspond à la quantité d'ordres LOs postés à k ticks du meilleur prix ask. Il faut également remarquer que dans ce cadre, il y a nécessairement un chevauchement des files d'attente bid et ask afin de laisser latitude au prix de varier suffisamment. Enfin, des conditions aux limites $a_\infty(t) = a_\infty = cte$ et $b_\infty(t) = b_\infty = cte$ sont ajoutées de telle sorte que le carnet d'ordres ne soit jamais vide et afin de borner les prix bid P_t^b et ask P_t^a .

On introduit enfin pour la suite les notations suivantes représentant la profondeur cumulée (cumulative depth) jusqu'à l'indice k respectivement de chaque côté du carnet d'ordres :

$$A_k(t) = \sum_{i=1}^k a_i(t)$$

$$B_k(t) = \sum_{i=1}^k b_i(t)$$




FIGURE 25.1 – Modélisation du carnet d'ordres

25.1 Processus de Poisson multidimensionnel

Considérons, un seul côté du carnet d'ordre, par exemple les ordres de ventes (Ask). On fait les hypothèses suivantes pour l'arrivée des différents types d'ordres :

- **Limit Orders** : leur arrivée dans la file k suit un processus de Poisson d'intensité λ_k^L .
- **Market Orders** : leur arrivée suit un processus de Poisson d'intensité λ^M .
- **Cancellation Orders** : l'annulation d'un ordre LO quelqu'il soit suit un processus de Poisson d'intensité λ^C .
- **Taille des ordres** : normalisés à 1 pour tous les ordres quelque soit leur type
- **Indépendance** : tous les processus ici en jeu sont supposés indépendants

Dans ce cadre, $A_k(t)$ peut donc être vu comme une chaîne de Markov ayant pour toute date t la même distribution stationnaire¹ $\pi_k(n) = \text{Proba}(A_k(t) = n)$ et correspondant à un processus arrivée-départ (birth-death) d'intensités respectives :

$$\Lambda_k^L(n) = \Lambda_k^L = \sum_{i=1}^k \lambda_i^L$$

$$\lambda^M + n\lambda^C$$

La forme matricielle du générateur infinitésimal de $\pi_k(n)$ peut alors classiquement s'écrire sous la forme suivante :

$$\begin{pmatrix} -\Lambda_k^L & \Lambda_k^L & & \\ \lambda^M + \lambda^C & -(\Lambda_k^L + \lambda^M + \lambda) & \Lambda_k^L & \\ & \lambda^M + 2\lambda^C & -(\Lambda_k^L + \lambda^M + 2\lambda^C) & \Lambda_k^L \\ & & & \ddots \end{pmatrix}$$

Dans ce cadre, toutes les distributions peuvent alors s'écrire, en premier lieu celle de $A_k(t)$:

$$\pi_k(n) = \pi_k(0) \prod_{i=1}^n \frac{\Lambda_k^L}{\lambda^M + i\lambda^C}$$

$$\pi_k(0) = \left(\sum_{n=0}^{\infty} \prod_{i=1}^n \frac{\Lambda_k^L}{\lambda^M + i\lambda^C} \right)^{-1}$$

De même la distribution du best ask P_t^a peut être également formulée explicitement en remarquant qu'il correspond au prix de la première file k telle que $A_{k-1}(t) = 0$ et $A_k(t) \neq 0$.

¹A condition que $\lambda^C > 0$

En considérant à présent les deux parties, ask et bid, du carnet d'ordres ainsi modélisées et en notant (N_t^i) tous les processus de Poisson en jeu, on peut en réalité écrire la dynamique du prix mid $P_t = \frac{1}{2} (P_t^A + P_t^B)$ sous la forme suivante, en s'appuyant sur les deux générateurs infinitésimaux des deux parties du carnet d'ordres X_t :

$$dP_t = \sum_i F_i(X_t) dN_t^i$$

$$P_t = P_0 + \sum_i \int_0^t F_i(X_u) dN_u^i$$

Dans cette formulation, la fonction $F_i(X_t)$ représente la contribution du saut N_t^i à la variation du prix et peut s'exprimer explicitement à l'aide des variables du modèle. On peut alors montrer (cf. Abergel) que ce processus markovien est non seulement ergodique mais qu'en plus il converge vers une diffusion brownienne à grandes échelles et dont la volatilité peut également s'exprimer explicitement à l'aide des variables du modèle.

En pratique, on préfère considérer des modèles restreints avec $K = 1$ ou $K = 2$, afin d'explicitier les probabilités de hausse (et donc également de baisse) en fonction de l'état du carnet d'ordre (voir Cont, de Larrard, Avelaneda) :

$$Proba_t^{up}(b_1(t), a_1(t))$$

$$Proba_t^{up}(b_2(t), b_1(t), a_2(t))$$

Certaines stratégies d'arbitrage du carnet d'ordre sont en effet basées sur ces valeurs clefs (envoi de signaux si ces probabilités dépassent un certain seuil significatif).

25.2 Modèle ACD multidimensionnel

Afin d'inclure dans la modélisation le clustering (autocorrélation positive) des ordres (MOs et LOs et même COs) observés empiriquement, on peut utiliser les modèles économétriques type ACD en lieu et place des processus de Poisson. Inspiré des modèles GARCH, l'idée des modèles ACD est de considérer que la durée entre deux événements (en l'occurrence ici l'arrivée d'un ordre, LO, MO ou CO) normalisée par son espérance conditionnelle est un processus stationnaire :

$$x_t = \psi_t \varepsilon_t$$

$$\psi_t = E_{t-1}[x_t]$$

Le modèle $ACD(m, q)$ s'écrit comme suit :

$$\psi_t = \omega + \sum_{j=1}^m \alpha_j x_{t-j} + \sum_{j=1}^q \beta_j \psi_{t-j}$$

Pour l'estimation des processus (similaire aux modèles GARCH), on travaillera sur des données préalablement désaisonnalisées $x_t = \tilde{x}_t.s(t)$ avec $s(t)$ un facteur de saisonnalité déterministe, estimé sur un historique journalier récent. Beaucoup d'extensions à ce modèle existent : ACM-ACD, EACD, log-ACD, GACD...

Ce cadre est en fait similaire à celui de la partie précédente mais avec des processus de Poisson à intensité stochastique. On peut également aboutir à des résultats similaires pour les distributions en jeu bien que plus complexes et beaucoup moins explicites. Surtout la propriété d'ergodicité et de diffusion brownienne à grandes échelles est également présente sous certaines conditions.

25.3 Processus de Hawkes multidimensionnel

Afin de non seulement modéliser ces caractéristiques empiriques de clustering des ordres mais également les interdépendances entre les différentes files d'ordres en particulier, bid et ask, on utilise plutôt les processus d'Hawkes qui permettent d'aboutir à des carnets d'ordres très réalistes. Un processus de Hawkes est un processus markovien, linéaire, auto-excitant de kernel exponentiel $\nu(t) = \sum_{j=1}^P \alpha_j e_j^{-\beta_j t}$: i.e. un processus de Poisson dont l'intensité dépend de l'historique de sauts de ce même processus et est défini comme suit

$$\begin{aligned}\lambda_t &= \lambda_0 + \int_0^t \nu(t-s) dN_s \\ &= \lambda_0 + \int_0^t \sum_{j=1}^P \alpha_j e_j^{-\beta_j(t-s)} dN_s\end{aligned}$$

La condition de stationnarité d'un tel processus s'écrit comme suit :

$$\sum_{j=1}^P \frac{\alpha_j}{\beta_j} < 1$$

La version multidimensionnelle des processus de Hawkes s'écrit comme suit :

$$\lambda_t^m = \lambda_0^m + \sum_{n=1}^M \int_0^t \sum_{j=1}^P \alpha_j e_j^{-\beta_j(t-s)} dN_s^n$$

Reprenons à présent la modélisation des carnet d'ordres en postulant que les MOs et les LOs suivent à présent des processus de Hawkes, les COs suivant toujours un processus de Poisson. On peut alors montrer que les propriétés d'ergodicité et de diffusion à grandes échelles sont également garanties dans ce cadre.

Pour finir, prenons le cas particulier d'un carnet d'ordre modélisé comme suit, toutes files d'ordres LOs suivant le même processus :

$$\begin{cases} \lambda_t^M &= \lambda_0^M + \int_0^t \alpha_{MM} e_j^{-\beta_{MM}(t-s)} dN_s^M \\ \lambda_t^L &= \lambda_0^L + \int_0^t \alpha_{LM} e_j^{-\beta_{LM}(t-s)} dN_s^M + \int_0^t \alpha_{LL} e_j^{-\beta_{LL}(t-s)} dN_s^L \end{cases}$$




FIGURE 25.2 – Processus de Hawkes




FIGURE 25.3 – Spreads bid-ask dans un modèle à processus de Hawkes

Nous avons ainsi modélisé, non seulement l'effet clustering au sein de chaque type d'ordres (effets MM et LL) mais également l'impact des ordres MOs sur les ordres LOs (effet LM mais pas ML). Le graphique suivant compare l'espérance de la distribution des spreads bid-ask selon trois modèles : Poisson, MM+LL, MM+LL+LM

26 Problèmes d'estimation en haute-fréquence

26.1 Bruit de microstructure

Comme on l'a vu précédemment les processus de prix ne se comportent donc pas comme des semi-martingales d'Itô et deviennent très vite discrets à faible échelle de temps (en dessous de la minute) non seulement par ce que les transactions ne s'effectuent pas de façon régulière (données asynchrones) mais également et surtout à cause du tick size. De plus à ces échelles là on constate un fort caractère mean-reverting. Pour toutes ces raisons, les estimateurs classiques de volatilité et de corrélation sont très biaisés et bruités à ces fréquences là¹. Or ils se retrouvent absolument partout : estimation du Market Impact, trading optimal, prédiction de volatilité, mesure de risque, probabilités d'exécution, valorisation d'options...

Certaines mesures alternatives ont été proposées. Il existe par exemple toute une littérature pour estimer de façon plus satisfaisante la variance intégrée $\int_0^t \sigma_u^2 du$ à des temps d'échelle très faibles mais ils ne sont en pratique pas adaptés à ce type de bruit de microstructure. Pour la covariance/corrélation, certains auteurs ont proposé des schémas d'interpolation des données afin de traiter ainsi le problème des données asynchrones plus crucial ici que pour la volatilité (DaCorogna par exemple). Mais ces estimateurs sont biaisés également. L'estimateur d'Hayashi-Yoshida plutôt efficace pour traiter les données asynchrones ne résiste pourtant pas à ce type de bruit de microstructure. Ces méthodes alternatives sont donc nécessaires. Il y a en pratique deux grandes approches pour corriger ces biais de microstructure et que nous allons nous voir à présent.

26.2 Approche macroscopique

L'idée de ce type d'approches est de partir d'une modélisation diffusive des prix valables à échelles longues et d'opérer des corrections ou transformations sur des échelles plus faibles afin de retrouver les mêmes comportement de microstructure. L'une des premières idées à été de considérer des modèles à erreurs d'arrondis. Considérons sur un intervalle de temps $[0, t]$ un prix P_t suivant un modèle diffusif à échelles longues et un échantillon de n éléments de ce prix sur cet intervalle à l'échelle de temps $\Delta t = \tau = \frac{t}{n}$ ainsi qu'une valeur d'arrondi associée $\alpha_n \rightarrow 0$. L'arrondi suivant

¹Très significativement, les volatilité et corrélation réalisées respectivement surestiment systématiquement la volatilité et la corrélation réelles.




FIGURE 26.1 – Volatilité réalisée à différents temps d'échelles




FIGURE 26.2 – Corrélation réalisée à différents temps d'échelle

décrit alors relativement bien le comportement de microstructure :

$$P_{\frac{i}{n}}^{\alpha_n} = \alpha_n \left\lfloor \frac{P_{\frac{i}{n}}}{\alpha_n} \right\rfloor$$

Le modèle est ensuite typiquement estimé par transformée d'ondelettes. Malheureusement pour les échelles de temps extrêmement fines, cette approche trouve ses limites et n'est plus valide. De plus se pose le problème du choix exogène et arbitraire de la série de prix à échelles longues sur laquelle se base le modèle et pour lequel il est relativement sensible (prix 10 secondes, 1 minutes, 5 minutes, 20 minutes...).

Rosenbaum propose pour cela d'étendre cette approche pour en corriger les défauts à l'aide de zone d'incertitudes (cf. article et présentations de Rosenbaum). Les estimateurs classiques de volatilité réalisée et Hayashi-Yamada pour la corrélation sont alors directement appliqués sur les prix ainsi corrigés pour tenir compte du bruit de microstructure. On obtient alors des résultats très cohérents et non biaisés même à échelles de temps extrêmement fines.

26.3 Approche microscopique

Ici, l'approche est plutôt bottom-up et part d'un modèle microscopique du carnet d'ordre pour modéliser les prix à échelles de temps plus élevées. Plutôt que des modèles de Poisson multidimensionnels, les processus de Hawkes sont le plus souvent utilisés car aboutissant à des résultats beaucoup plus réalistes et en phase avec les données empiriques.

26.3.1 Volatilité

On considère ici un modèle de prix au niveau mesoscopique (HF). Le prix est ici sommairement modélisée comme la résultante stationnaire et mean-reverting de deux processus de Hawkes Upward et Downward J_t^+ et J_t^- et correspondant respectivement aux pressions acheteuse et vendeuse du marché :

$$P_t = P_0 + J_t^+ - J_t^-$$

Les intensités de ces deux processus peuvent s'écrire comme suit :

$$\begin{cases} \lambda_t^+ &= \lambda_0^+ + \int_0^t \alpha e^{-\beta(t-s)} dJ_s^- \\ \lambda_t^- &= \lambda_0^- + \int_0^t \alpha e^{-\beta(t-s)} dJ_s^+ \end{cases}$$

On a donc un modèle à excitations croisées uniquement (pas d'auto-excitation) et absolument symétriques afin d'amplifier le caractère mean-reverting constaté empiriquement sur les prix à ces échelles de temps. Bacry montre que le moment d'ordre 2 du prix ainsi généré peut s'écrire comme suit en fonction de l'échelle de temps $\tau = \Delta t$:




FIGURE 26.3 – Volatilité Réalisée vs Volatilité Hawkes

$$E \left[(P_t(\tau))^2 \right] = \Lambda \tau \left(\kappa^2 + (1 - \kappa^2) \frac{1 - e^{-\gamma \tau}}{\gamma \tau} \right)$$

$$\begin{cases} \Lambda &= \frac{\lambda_0^+ + \lambda_0^-}{1 - \frac{\alpha}{\beta}} \\ \kappa &= \frac{1}{1 + \frac{\alpha}{\beta}} \\ \gamma &= \alpha + \beta \end{cases}$$

Le graphe suivant compare sur différentes échelles de temps, la volatilité réalisée et celle issue de ce modèle après l'avoir estimé sur des données à l'échelle de temps correspondante :

26.3.2 Corrélation

On reprend la modélisation des prix utilisé pour l'estimation de la volatilité, appliquée cette fois sur deux actifs :

$$P_t^1 = P_0^1 + J_t^1 - J_t^2$$

$$P_t^2 = P_0^2 + J_t^3 - J_t^4$$

On a donc affaire un processus de Hawkes de dimension 4 $J_t = (J_t^1, J_t^2, J_t^3, J_t^4)^t$ dont l'intensité est spécifiée comme suit :

$$\lambda_t = \lambda_0 + \int_0^t \begin{pmatrix} 0 & \phi^{12} & \phi^{13} & \\ \phi^{12} & & & \phi^{24} \\ \phi^{31} & & & \phi^{34} \\ & \phi^{24} & \phi^{34} & \end{pmatrix} (t-s) dJ_t$$

Avec :

$$\phi^{ij}(t-s) = \alpha_{ij} e^{-\beta_{ij}(t-s)}$$

On peut faire les remarques suivantes concernant cette modélisation :

- Il n'y a pas d'auto-excitation des processus de Hawkes individuels : $\phi^{11}(t) = \phi^{22}(t) = \phi^{33}(t) = \phi^{44}(t) = 0$
- Les effets Upward et Downward sont supposés symétriques aux seins des deux prix P_t^1 et P_t^2 : $\phi^{12}(t) = \phi^{21}(t)$; $\phi^{13}(t) = \phi^{31}(t)$; $\phi^{24}(t) = \phi^{42}(t)$ et $\phi^{34}(t) = \phi^{43}(t)$
- Les deux prix P_t^1 et P_t^2 s'influencent chacun de façon positive : $\phi^{14}(t) = \phi^{23}(t) = \phi^{32}(t) = \phi^{41}(t) = 0$

Bien que complexe, on peut aboutir à une formulation explicite de la corrélation au sein de ce modèle à l'échelle de temps voulue. On peut juger de la qualité de cette estimation à travers le graphe suivant qui compare sur différentes échelles de temps, la corrélation réalisée et celle issue de ce modèle après l'avoir estimé sur des données à l'échelle de temps correspondante :




FIGURE 26.4 – Corrélation Réalisée vs Corrélation Kawkes

27 Formation des prix et Market Impact

Le trading haute-fréquence a ouvert de nouvelles perspectives pour mieux comprendre le processus de formation des prix. On peut isoler deux effets complémentaires et correspondant de façon évidente à des processus sur des échelles différentes :

- **Effet informationnel (macro)** : autrement dit, l'impact pur de l'information sur les prix (Price discovery). Cet effet est majoritaire même à haute fréquence, en cas de news importante (publication des résultats pour une entreprise, chiffre macro, information géopolitique importante...) auquel cas, les prix « shiftent » brutalement (news impact).
- **Effet mécanique (micro)** : formation mécanique des prix dû au fonctionnement même du carnet d'ordres. C'est la plupart du temps l'effet majoritaire à haute fréquence sauf en cas de news impact.

Cet effet mécanique de formation des prix est absolument crucial pour un trader haute-fréquence, d'autant plus qu'il se matérialise au travers d'un coût de trading spécifique lié au phénomène de Market impact déjà vu précédemment. Pour rappel le Market Impact correspond au mouvement du prix juste après l'exécution d'un MO, cet impact dépendant de façon positive à la taille v_t de l'ordre posté.

Pour mieux le comprendre, le modéliser et l'analyser, certains chercheurs ont choisi de passer par une modélisation du carnet d'ordre (échelle microscopique) par processus de Hawkes afin d'expliquer ce phénomène qui s'observe de façon agrégée à des échelles de temps plus élevées, en l'occurrence à l'échelle mésoscopique. Cette approche a eu des résultats assez probants comme le montre le graphe suivant qui compare le Market Impact théorique et empirique :

Néanmoins, la complexité des modèles microscopiques interdit de les utiliser pour résoudre des problèmes de trading optimal sous peine de se retrouver avec des problèmes excessivement complexes à résoudre, même numériquement. Pour obtenir des solutions exploitables, on préfère donc s'orienter directement sur des modèles mésoscopiques. A cet effet Gatheral a introduit une formulation générale du Market impact, sous la forme suivante :

$$MI_t = \int_0^t f_s(v_s) K(t-s) ds$$

La fonction $f_t(v_t)$ correspond à l'impact immédiat du trade de volume v_t et $K(t)$ est un kernel d'atténuation de cet impact (decay kernel). Cette forme doit néanmoins être contrainte pour empêcher tout arbitrage ou stratégie de manipulation haute-fréquence




FIGURE 27.1 – Modélisation du Market Impact par processus de Hawkes

du prix. Très classiquement, on utilise souvent une forme en décroissance exponentielle ou une loi puissance pour le kernel :

$$\begin{cases} K(t-s) &= \lambda e^{-\frac{t-s}{\lambda}} \\ K(t-s) &= \frac{(1-t-s)^{-\gamma}}{\gamma-1} \end{cases}$$

Pour la fonction d'impact, on utilise habituellement une fonction dépendant non seulement du volume du trade v_t (de façon évidemment croissante) mais également du spread observé ψ_t de la volatilité σ_t et du volume V_t présent au sein du carnet d'ordre :

$$f_t(v_t) = \alpha \psi_t + \kappa \sigma_t \left(\frac{v_t}{V_t} \right)^\gamma$$

Dans cette expression, on a généralement $\gamma = \frac{1}{2}$.

Enfin, Lehalle a proposé une explication à la forme très particulière du Market Impact. Elle viendrait selon lui essentiellement de la segmentation du marché au sein des Market Makers. Un Market Maker est essentiellement un fournisseur de liquidité au marché mais jusqu'à un certain point qui correspondent à leurs propres limites (risk threshold) de risque correspondant à leur risque d'inventaire et « d'adverse selection »¹, et pour lesquels ils se font rémunérer par la fourchette bid-ask

¹Autrement dit, le risque d'être toujours dans le mauvais sens des prix du fait de traders mieux informés, soit en directionnel, soit en StatArb.



FIGURE 27.2 – Formation du Market Impact

qu'ils proposent sur les prix. Ces limites peuvent en conséquence provoquer des effets moutonniers importants car lorsqu'elles sont cassées, les excès d'inventaire, dans un sens ou dans l'autre sont alors déversés sur le marché. Cet aspect est tout de même à nuancer selon le type de marché. Typiquement, sur les marchés Order-Driven, les budgets de risque sont faibles et les inventaires également. Une limite de risque cassée implique un faible effet moutonnier car l'inventaire déversé sur le marché est faible. Sur les marchés Quote-Driven, les budgets de risque sont plus élevés, nécessairement car ces marchés sont moins liquides, et les inventaires plus élevés également. Cette fois-ci, lorsqu'une limite est cassée, les excès d'inventaires déversés peuvent être importants et créer un effet moutonnier significatif. Ainsi le marché est-il segmenté en terme de liquidité et plus exactement de durée de liquidité (liquidity duration) i.e. la durée moyenne pour qu'un Market Maker atteigne sa limite de risque. Durant la partie « Transient », les Market Maker cassent un à un leur limites, ne restant en jeu et de moins ne moins nombreux que ceux qui des durations de liquidité plus longues. Ceci expliquerait donc la forme concave du « Transient Impact ». Au moment du « temporary Impact », le Market Maker ayant la durée en liquidité la plus longue casse sa limite et déverse à son tour son excès de liquidité. On assiste alors à un effet cumulé d'ajustement dû à ces excès de liquidité déversés en cumulé sur le marché : on rentre dans un la phase de « Decay » jusqu'à un état stable matérialisant le « Permanent Impact » final.

28 Trading optimal

Modélisation mesoscopique => solution explicites aux équations HJB

28.1 Exécution optimale

Liquidity taking => vitesse de trading v_t des ordres MOs ?

Almgren-Chriss :

- **Permanent Impact :** $-bv_t$
- **Temporary Impact :** $f(v_t) = kv_t^a$
- optimisation du P&L
- pénalité quadratique α de l'inventaire à maturité
- pénalité quadratique e l'inventaire courant ($\Leftrightarrow$ aversion au risque avec fonction d'utilité exponentielle)

Le prix :

$$dS_t^v = -bv_t dt + \sigma dW_t$$

Le cash

$$dX_t^v = (S_t^v - f(v_t)) v_t dt$$

L'inventaire

$$dQ_t^v = -v_t dt$$

Contrôle optimal

$$H^\nu(t, x, S, q) = E_{t,x,S,q} \left[X_T^v + Q_T^v (S_T^v - \alpha Q_T^v) - \phi \int_0^T (Q_u^v)^2 du \right]$$

$$H(t, x, S, q) = \sup_v H^\nu(t, x, S, q)$$

HJB

$$0 = \left(\partial_t + \frac{1}{2} \sigma^2 \partial_{SS} \right) H - \phi q^2 + \sup_v \{ (v(S - f(v)) \partial_x - bv \partial_S - v \partial_q) H \}$$

Ansatz

$$H(t, x, S, q) = x + qS + h(t, q)$$

28.2 Market Making optimal

Liquidity providing => trouver les ordres limites sell LOs $S_t + \delta_t^+$ et buy LOs $S_t - \delta_t^-$ à poster !

Avelaneda-Stoikov

Le prix :

$$dS_t = \sigma dW_t$$

Les MOs suivent des processus de Poisson d'intensité λ_t^+ et λ_t^-

Les LOs sont exécutés selon des processus de Poisson $N_t^{\delta^+}$ et $N_t^{\delta^-}$ d'intensité conditionnelles (à l'arrivée de MOs) respectivement $e^{-k\delta_t^+}$ et $e^{-k\delta_t^-}$

Le cash :

$$dX_t^\delta = (S_t - \delta_t^-) dN_t^{\delta^-} - (S_t + \delta_t^+) dN_t^{\delta^+}$$

L'inventaire :

$$Q_t^\delta = N_t^{\delta^-} - N_t^{\delta^+}$$

Contrôle optimal :

$$H^\delta(t, x, q, S) = E_{t,x,S,q} \left[X_T^\delta + Q_T^\delta (S_T^\delta - \alpha X_T^\delta) - \phi \int_0^T (Q_u^\delta)^2 du \right]$$

$$H(t, x, q, S) = \sup_{\delta^{+-}} H^\delta(t, x, q, S)$$

HJB

$$\begin{aligned} 0 = & \left(\partial_t + \frac{1}{2} \sigma^2 \partial_{SS} \right) H - \phi q^2 \\ & + \lambda_t^+ \sup_{\delta^+} \left\{ e^{-k\delta_t^+} \left(H(t, x + S + \delta^+, q - 1, S) - H \right) \right\} \\ & + \lambda_t^- \sup_{\delta^-} \left\{ e^{-k\delta_t^-} \left(H(t, x - S - \delta^-, q + 1, S) - H \right) \right\} \end{aligned}$$

Ansatz

$$H(t, x, q, S) = x + qS + h(t, q)$$

28.3 Hedging optimal

PBS en suspens :

- estimation des modèles
- MFG
- modèle optimal de trading directionnel